

ĐẠI HỌC BÁCH KHOA HÀ NỘI
TRƯỜNG ĐIỆN - ĐIỆN TỬ



ĐỒ ÁN TỐT NGHIỆP ĐẠI HỌC

Đề tài:

**LiRA-HEART: Lightweight Resnet-Autoencoder
Hybrid Extraction and Reconstruction of Fetal ECG**

Sinh viên thực hiện: NGUYỄN NGỌC SƠN

Lớp ET-LUH 01 K66

Giảng viên hướng dẫn: TS. HÀN HUY DŨNG

Hà Nội, June 27, 2025

TRƯỜNG ĐẠI HỌC BÁCH KHOA HÀ NỘI
VIỆN ĐIỆN TỬ - VIỄN THÔNG



ĐỒ ÁN TỐT NGHIỆP ĐẠI HỌC

Đề tài:

**LiRA-HEART: Lightweight Resnet-Autoencoder
Hybrid Extraction and Reconstruction of Fetal ECG**

Sinh viên thực hiện: NGUYỄN NGỌC SƠN

Lớp ET-LUH 01 - K66

Mã số sinh viên: 20213771

Giảng viên hướng dẫn: TS. HÀN HUY DŨNG

Cán bộ phản biện:

Hà Nội, June 27, 2025

ĐÁNH GIÁ ĐỒ ÁN TỐT NGHIỆP

(DÀNH CHO CÁN BỘ THÀNH VIÊN HỘI ĐỒNG)

Hội đồng số:.....

Họ và tên sinh viên:..... MSSV:.....

Cán bộ thành viên HĐ:

STT	Tiêu chí (Điểm tối đa)	Hướng dẫn đánh giá tiêu chí	Điểm tiêu chí
1	Chất lượng slides/Bản vẽ kỹ thuật (1,5 điểm)	Sử dụng các minh họa hỗ trợ: Hình ảnh, biểu đồ rõ nét và phù hợp, dễ hiểu Không quá nhiều từ, biết sử dụng từ khoá; bố cục logic, có đánh số trang	
2	Kỹ năng thuyết trình (1,5 điểm)	Tự tin, làm chủ nội dung trình bày, đúng thời gian quy định Dễ hiểu, dễ theo dõi, lô-gic, lời cuốn.	
3	Nội dung và kết quả đạt được (4 điểm)	Nêu rõ tính cấp thiết, ý nghĩa khoa học và thực tiễn của đề tài, các vấn đề và các giả thuyết, phạm vi ứng dụng của đề tài. Thực hiện đầy đủ quy trình nghiên cứu: Đặt vấn đề, mục tiêu đề ra, phương pháp nghiên cứu/ giải quyết vấn đề, kết quả đạt được, đánh giá và kết luận. Nội dung và kết quả được trình bày một cách logic và hợp lý, được phân tích và đánh giá thỏa đáng. Biện luận phân tích kết quả mô phỏng/ phần mềm/ thực nghiệm, so sánh kết quả đạt được với kết quả trước đó có liên quan. Chỉ rõ phù hợp giữa kết quả đạt được và mục tiêu ban đầu đề ra đồng thời cung cấp lập luận để đề xuất hướng giải quyết có thể thực hiện trong tương lai. Hàm lượng khoa học/ độ phức tạp cao, có tính mới/ tính sáng tạo trong nội dung và kết quả đồ án.	
4	Trả lời câu hỏi (2,5 điểm)	Trả lời ngắn gọn, chính xác, đi thẳng vào vấn đề của câu hỏi. Nắm vững kiến thức cơ bản liên quan đến lĩnh vực nghiên cứu/ công việc của đồ án.	
5	Điểm thành tích (1 điểm)	Có bài báo KH được đăng hoặc chấp nhận đăng/ đạt giải SV NCKH giải 3 cấp Trường trở lên/ Các giải thưởng khoa học trong nước, quốc tế từ giải 3 trở lên/ Có đăng ký bằng phát minh sáng chế. (1 điểm) Được báo cáo tại hội đồng cấp Trường trong hội nghị SV NCKH nhưng không đạt giải từ giải 3 trở lên/ Đạt giải khuyến khích trong cuộc thi khoa học trong nước, quốc tế/ Kết quả đồ án là sản phẩm ứng dụng có tính hoàn thiện cao, yêu cầu khối lượng thực hiện lớn. (0,5 điểm)	
Điểm tổng các tiêu chí:			
Điểm bảo vệ:			

Cán bộ thành viên HĐ
(Ký và ghi rõ họ tên)

ĐÁNH GIÁ QUYỀN ĐỒ ÁN TỐT NGHIỆP

(DÙNG CHO GIẢNG VIÊN HƯỚNG DẪN)

Họ và tên giảng viên đánh giá:

Họ và tên sinh viên:..... MSSV:.....

Tên đồ án:

ST T	Tiêu chí (Điểm tối đa)	Hướng dẫn đánh giá tiêu chí	Điểm tiêu chí
1	Thái độ làm việc (2,5 điểm)	Nghiêm túc, tích cực và chủ động trong quá trình làm ĐATN Hoàn thành đầy đủ và đúng tiến độ các nội dung được GVHD giao	
2	Kỹ năng viết quyền ĐATN (2 điểm)	Trình bày đúng mẫu quy định, bố cục các chương logic và hợp lý: Bảng biểu, hình ảnh rõ ràng, có tiêu đề, được đánh số thứ tự và được giải thích hay đề cập đến trong đồ án, có căn lề, dấu cách sau dấu chấm, dấu phẩy, có mở đầu chương và kết luận chương, có liệt kê tài liệu tham khảo và có trích dẫn, v.v. Kỹ năng diễn đạt, phân tích, giải thích, lập luận: Cấu trúc câu rõ ràng, văn phong khoa học, lập luận logic và có cơ sở, thuật ngữ chuyên ngành phù hợp, v.v.	
3	Nội dung và kết quả đạt được (5 điểm)	Nêu rõ tính cấp thiết, ý nghĩa khoa học và thực tiễn của đề tài, các vấn đề và các giả thuyết, phạm vi ứng dụng của đề tài. Thực hiện đầy đủ quy trình nghiên cứu: Đặt vấn đề, mục tiêu đề ra, phương pháp nghiên cứu/ giải quyết vấn đề, kết quả đạt được, đánh giá và kết luận. Nội dung và kết quả được trình bày một cách logic và hợp lý, được phân tích và đánh giá thỏa đáng. Biện luận phân tích kết quả mô phỏng/ phần mềm/ thực nghiệm, so sánh kết quả đạt được với kết quả trước đó có liên quan. Chỉ rõ phù hợp giữa kết quả đạt được và mục tiêu ban đầu đề ra đồng thời cung cấp lập luận để đề xuất hướng giải quyết có thể thực hiện trong tương lai. Hàm lượng khoa học/ độ phức tạp cao, có tính mới/tính sáng tạo trong nội dung và kết quả đồ án.	
4	Điểm thành tích (1 điểm)	Có bài báo KH được đăng hoặc chấp nhận đăng/ đạt giải SV NCKH giải 3 cấp Trường trở lên/ Các giải thưởng khoa học trong nước, quốc tế từ giải 3 trở lên/ Có đăng ký bằng phát minh sáng chế. (1 điểm) Được báo cáo tại hội đồng cấp Trường trong hội nghị SV NCKH nhưng không đạt giải từ giải 3 trở lên/ Đạt giải khuyến khích trong cuộc thi khoa học trong nước, quốc tế/ Kết quả đồ án là sản phẩm ứng dụng có tính hoàn thiện cao, yêu cầu khối lượng thực hiện lớn. (0,5 điểm)	
Điểm tổng các tiêu chí:			
Điểm hướng dẫn:			

Cán bộ hướng dẫn
(Ký và ghi rõ họ tên)

ĐÁNH GIÁ QUYỀN ĐỒ ÁN TỐT NGHIỆP (DÙNG CHO CÁN BỘ PHẢN BIỆN)

Giảng viên đánh giá:.....

Họ và tên sinh viên: MSSV:

Tên đồ án:

STT	Tiêu chí (Điểm tối đa)	Hướng dẫn đánh giá tiêu chí	Điểm tiêu chí
1	Trình bày quyển ĐATN (4 điểm)	Đồ án trình bày đúng mẫu quy định, bố cục các chương logic và hợp lý: Bảng biểu, hình ảnh rõ ràng, có tiêu đề, được đánh số thứ tự và được giải thích hay đề cập đến trong đồ án, có căn lề, dấu cách sau dấu chấm, dấu phẩy, có mở đầu chương và kết luận chương, có liệt kê tài liệu tham khảo và có trích dẫn, v.v. Kỹ năng diễn đạt, phân tích, giải thích, lập luận: cấu trúc câu rõ ràng, văn phong khoa học, lập luận logic và có cơ sở, thuật ngữ chuyên ngành phù hợp, v.v.	
2	Nội dung và kết quả đạt được (5,5 điểm)	Nêu rõ tính cấp thiết, ý nghĩa khoa học và thực tiễn của đề tài, các vấn đề và các giả thuyết, phạm vi ứng dụng của đề tài. Thực hiện đầy đủ quy trình nghiên cứu: Đặt vấn đề, mục tiêu đề ra, phương pháp nghiên cứu/ giải quyết vấn đề, kết quả đạt được, đánh giá và kết luận. Nội dung và kết quả được trình bày một cách logic và hợp lý, được phân tích và đánh giá thỏa đáng. Biện luận phân tích kết quả mô phỏng/ phần mềm/ thực nghiệm, so sánh kết quả đạt được với kết quả trước đó có liên quan. Chỉ rõ phù hợp giữa kết quả đạt được và mục tiêu ban đầu đề ra đồng thời cung cấp lập luận để đề xuất hướng giải quyết có thể thực hiện trong tương lai. Hàm lượng khoa học/ độ phức tạp cao, có tính mới/ tính sáng tạo trong nội dung và kết quả đồ án.	
3	Điểm thành tích (1 điểm)	Có bài báo KH được đăng hoặc chấp nhận đăng/ đạt giải SV NCKH giải 3 cấp Trường trở lên/ Các giải thưởng khoa học trong nước, quốc tế từ giải 3 trở lên/ Có đăng ký bằng phát minh sáng chế. (1 điểm) Được báo cáo tại hội đồng cấp Trường trong hội nghị SV NCKH nhưng không đạt giải từ giải 3 trở lên/ Đạt giải khuyến khích trong cuộc thi khoa học trong nước, quốc tế/ Kết quả đồ án là sản phẩm ứng dụng có tính hoàn thiện cao, yêu cầu khối lượng thực hiện lớn. (0,5 điểm)	
Điểm tổng các tiêu chí:			
Điểm phản biện:			

Cán bộ phản biện
(Ký và ghi rõ họ tên)

LỜI NÓI ĐẦU

Sức khỏe thai nhi trong thai kỳ luôn là mối quan tâm hàng đầu trong y học sản khoa hiện đại. Việc theo dõi và đánh giá tình trạng tim mạch của thai nhi đóng vai trò cực kỳ quan trọng trong việc phát hiện sớm các bất thường, từ đó can thiệp kịp thời, giúp giảm thiểu nguy cơ tử vong chu sinh. Điện tim thai nhi (fetal electrocardiogram – fECG) là một công cụ chẩn đoán không thể thiếu, giúp phát hiện các vấn đề như loạn nhịp tim, suy tim, hoặc stress trong quá trình chuyển dạ.

Tuy nhiên, việc thu nhận và phân tích tín hiệu fECG là một thách thức lớn, chủ yếu do tín hiệu này có biên độ rất nhỏ và dễ bị lấn át bởi nhiễu và tín hiệu điện tim của mẹ (maternal ECG – mECG). Chính vì vậy, việc tách biệt tín hiệu fECG từ tín hiệu aECG (abdominal ECG) mà không gây xâm lấn vẫn luôn là vấn đề khó khăn trong thực tế. Các phương pháp truyền thống như lọc thích nghi, phân tích thành phần độc lập (ICA), phân tích thành phần chính (PCA), hay trừ mẫu (template subtraction) đã được áp dụng trong việc trích xuất fECG. Tuy nhiên, các phương pháp này còn tồn tại nhiều hạn chế, chẳng hạn như dễ bị ảnh hưởng bởi nhiễu, phụ thuộc nhiều vào điều kiện tiền xử lý tín hiệu, hoặc yêu cầu số lượng kênh dữ liệu và mức độ xử lý phức tạp cao.

Trước những thách thức đó, Biến đổi Sóng liên tục (Continuous Wavelet Transform – CWT) đã nổi lên như một công cụ mạnh mẽ trong phân tích tín hiệu không ổn định như fECG, nhờ khả năng cung cấp biểu diễn thời–tần với độ phân giải đa mức, giúp tăng cường khả năng phát hiện các sóng quan trọng như QRS của thai nhi trong môi trường có nhiễu lớn. Tuy nhiên, việc ứng dụng CWT vẫn gặp khó khăn trong việc điều chỉnh các tham số và đảm bảo hiệu quả trong điều kiện thực tế.

Trong bối cảnh đó, đồ án này tập trung vào việc nghiên cứu và phát triển các phương pháp mới để giải quyết vấn đề phân tích tín hiệu fECG với độ chính xác cao. Mục tiêu chính của đồ án là xây dựng và triển khai một mô hình học sâu có khả năng phân tách tín hiệu fECG ra khỏi aECG, từ đó nâng cao hiệu quả phát hiện và phân tích tín hiệu trong điều kiện thực tế, đặc biệt là trong môi trường có nhiễu lớn. Mô hình này không chỉ hỗ trợ việc cải thiện độ chính xác trong quá trình phân tích mà còn hướng tới các ứng dụng lâm sàng trong việc theo dõi sức khỏe thai nhi một cách không xâm lấn và hiệu quả, góp phần vào việc phát hiện sớm các bất thường tim mạch và giảm thiểu nguy cơ tử vong chu sinh.

Đồ án tốt nghiệp này được hoàn thành dưới sự hướng dẫn tận tình của Thầy **Hàn Huy Dũng**, người đã không chỉ truyền đạt những kiến thức chuyên môn quý báu mà còn luôn đồng hành, động viên em trong suốt quá trình thực hiện. Chính sự tận tâm của Thầy là nguồn động lực to lớn giúp vượt qua nhiều khó khăn và thử thách trong quá trình

ngiên cứu.

Em cũng xin gửi lời cảm ơn đến các thầy cô trong **Hội đồng bảo vệ** đã dành thời gian đọc, nhận xét và đóng góp ý kiến quý báu, giúp em hoàn thiện hơn nội dung và cách trình bày của đề án.

LỜI CAM ĐOAN

Tôi tên là NGUYỄN NGỌC SƠN, mã số sinh viên 20213771, sinh viên lớp ET-LUH 01, khóa 66. Người hướng dẫn là TS. HÀN HUY DŨNG.

Tôi xin cam đoan rằng toàn bộ nội dung được trình bày trong báo cáo "LiRA-HEART: Lightweight ResNet-Autoencoder Hybrid Extraction and Reconstruction of Fetal ECG" là kết quả nghiên cứu và thực hiện của chính tôi. Mọi thông tin trích dẫn trong báo cáo đều tuân thủ nghiêm túc các quy định về sở hữu trí tuệ, và các tài liệu tham khảo đã được liệt kê đầy đủ, rõ ràng.

Tôi xin chịu hoàn toàn trách nhiệm về tính trung thực và nội dung của đồ án này.

Hà Nội, June 27, 2025

Người cam đoan

NGUYỄN NGỌC SƠN

MỤC LỤC

DANH MỤC KÝ HIỆU VÀ CHỮ VIẾT TẮT	i
DANH MỤC HÌNH VẼ	iii
DANH MỤC BẢNG BIỂU	iv
CHƯƠNG 1. CHƯƠNG MỞ ĐẦU	1
1.1 Bối cảnh và do chọn đề tài	1
1.2 Mục tiêu nghiên cứu	2
1.3 Phạm vi và giới hạn nghiên cứu	2
1.4 Đối tượng nghiên cứu	3
1.5 Cấu trúc báo cáo	3
CHƯƠNG 2. Tổng quan về tín hiệu ECG và FmECG	5
2.1 Giới thiệu tín hiệu ECG cơ bản	5
2.1.1 Các thành phần của tín hiệu ECG	5
2.1.2 Ứng dụng trong chẩn đoán tim mạch	5
2.2 Đặc điểm và ý nghĩa lâm sàng của Fetal ECG (FmECG)	7
2.2.1 Đặc điểm tín hiệu FmECG	7
2.2.2 Ý nghĩa và ứng dụng lâm sàng của FmECG	8
2.2.3 Nhiều và khó khăn trong việc phân biệt tín hiệu mẹ và tín hiệu thai nhi	9
2.3 Các phương pháp đã được nghiên cứu (ICA, Kalman, v.v.)	10
2.3.1 Các phương pháp truyền thống và khuyết điểm của chúng	10
2.3.2 Phương pháp phân tách tín hiệu dựa trên ICA (Independent Component Analysis)	11
2.3.3 Phương pháp Kalman Filter và ứng dụng trong tín hiệu y sinh	12
2.4 Lựa Chọn Phương Pháp	13

CHƯƠNG 3. Cơ sở lý thuyết về Sóng liên tục (CWT)	14
3.1 Giới thiệu về Sóng liên tục (CWT)	14
3.2 Nguyên lý toán học của CWT	14
3.2.1 Định nghĩa CWT và công thức	14
3.2.2 Phương trình tích phân liên tục	15
3.2.3 Xấp xỉ rời rạc trong tính toán CWT	15
3.2.4 Mối quan hệ giữa scale và tần số	16
3.3 Các loại Sóng mẹ (Mother Wavelets)	17
3.3.1 Các loại Sóng mẹ phổ biến	17
3.3.2 Tính chất của Sóng mẹ	18
3.3.3 Lý do chọn Mexh wavelet	19
3.4 Ưu điểm của CWT	20
3.4.1 Phân giải cao trong cả thời gian và tần số	20
3.4.2 Khả năng phân tích các tín hiệu không ổn định	21
3.4.3 Ứng dụng trong nhiều lĩnh vực	21
3.5 Giới thiệu các phương pháp mở rộng CWT	22
3.5.1 Biến đổi wavelet rời rạc (DWT)	22
3.5.2 CWT trong thời gian thực	23
3.5.3 Biến đổi wavelet chồng chất (Overlapped Wavelet Transform)	24
3.5.4 CWT và các sóng mẹ nâng cao	24
3.6 Ứng dụng của CWT trong phân tích tín hiệu	24
3.6.1 CWT trong thời gian thực	25
3.6.2 Các ứng dụng khác	25
3.6.3 Các ứng dụng trong kỹ thuật	26
3.7 Giới thiệu về Inverse Continuous Wavelet Transform (ICWT)	26
3.7.1 Công thức ICWT liên tục	26
3.7.2 Công thức ICWT rời rạc (Dạng Tổng Σ)	27
3.7.3 So sánh CWT với STFT	27
3.8 Những thách thức và hạn chế của CWT và ICWT	28

3.8.1	Chi phí tính toán cao	28
3.8.2	Vấn đề về nhiễu	29
3.8.3	Lựa chọn tham số phù hợp	29
3.8.4	Hạn chế ICWT	30
3.9	Tóm tắt	30
CHƯƠNG 4. Preprocessing		32
4.1	Flowchart tổng quan	32
4.2	Phân tích bộ dữ liệu huấn luyện	32
4.2.1	ADFECGDB – Bộ dữ liệu chính để huấn luyện	32
4.2.2	PCDB – Bộ dữ liệu kiểm tra khả năng khái quát	33
4.3	Stage 1: Tiền xử lý tín hiệu Abdominal ECG	33
4.3.1	Chuẩn hóa về khoảng $[-1,1]$	34
4.3.2	Lọc thông dải để giữ thành phần tần số liên quan	34
4.3.3	Tái mẫu về 250 Hz bằng nội suy	36
4.3.4	Chia cửa sổ cố định 4 giây	36
4.4	Stage 2: Sinh ảnh CWT (Scalogram Generation)	37
4.4.1	Phân chia dải tần $[10,100]$ Hz thành 10 băng	37
4.4.2	Ánh xạ thành 10 scale $\rightarrow$ ma trận 10×1000	38
4.4.3	Chuẩn hóa ma trận về $[0,1]$	38
CHƯƠNG 5. LiRA Model		40
5.1	Giới thiệu về mô hình AI	40
5.1.1	Mục đích	40
5.1.2	Loại mô hình	41
5.1.3	Ứng dụng thực tế	41
5.2	Dữ liệu và Tiền xử lý (Data and Preprocessing)	42
5.2.1	Tập dữ liệu	43
5.3	Cấu trúc mô hình (Model Architecture)	43
5.3.1	Kiến trúc tổng thể	43

5.3.2	Khối Residual và các khái niệm cơ bản	44
5.3.3	Encoder	46
5.3.4	Chức năng của BottleNeck	48
5.3.5	Decoder	48
5.4	Thuật toán và Phương pháp học (Algorithm and Learning Method) . . .	49
5.4.1	Thuật toán học	49
5.4.2	Các siêu tham số (Hyperparameters)	50
5.5	Stage 3: Estimation of the CWT representation of the fetal ECG signal using the LiRA model	51
5.6	Stage 4 Stage 5: Reconstructing the fetal ECG signal through inverse CWT and Detecting fetal heartbeat peaks.	52
CHƯƠNG 6. THÍ NGHIỆM VÀ KẾT QUẢ		54
6.1	Tiêu chí đánh giá LiRA Model	54
6.1.1	Accuracy	54
6.1.2	Precision	54
6.1.3	Recall	54
6.1.4	F1-Score	54
6.2	Tiêu chí đánh giá fecg dự đoán	55
6.2.1	Structural Similarity Index (SSIM)	55
6.2.2	L1 Loss (Mean Absolute Error)	55
6.2.3	Signal-to-Noise Ratio (SNR)	55
6.2.4	Mean Squared Error (MSE)	55
6.2.5	Root Mean Squared Error (RMSE)	55
6.2.6	Cosine Similarity	56
6.3	Kết Quả Đã Đạt Được Từ LiRA Model	56
6.4	So sánh với các kết quả trong các bài báo khác	58
CHƯƠNG 7. Thảo luận, kết quả và hướng phát triển		60
7.1	Tóm tắt kết quả chính	60
7.2	Thảo luận kết quả	60

7.3	Hạn chế của nghiên cứu	61
7.4	Hướng phát triển tương lai	62
KẾT LUẬN		64
TÀI LIỆU THAM KHẢO		65
PHỤ LỤC		68

DANH MỤC KÝ HIỆU VÀ CHỮ VIẾT TẮT

fECG	Fetal Electrocardiogram
AECG	Abdominal Electrocardiogram
mECG	Maternal Electrocardiogram
LiRA	LightResNet-AutoEncoder
CWT	Continuous Wavelet Transform
ICWT	Inverse Continuous Wavelet Transform
ICA	Independent Component Analysis
EKF	Extended Kalman Filter
SNR	Signal-to-Noise Ratio
RMSE	Root Mean Square Error
MAPE	Mean Absolute Percentage Error
PPV	Positive Predictive Value
F1 Score	F1 Score
Se	Sensitivity

DANH MỤC HÌNH VẼ

Hình 2.1	Hình ảnh tín hiệu ECG	6
Hình 2.2	mô phỏng cách đo aECG	7
Hình 2.3	Doppler màu siêu âm	8
Hình 2.4	aECG Được Thu Từ Bụng Mẹ	9
Hình 2.5	Kết Quả fECG Từ ICA	12
Hình 3.1	Morlet Wavelet	16
Hình 3.2	Các Morlet Wavelet	17
Hình 3.3	Mexican Hat Wavelet	19
Hình 3.4	Độ Phân Giải CWT	21
Hình 3.5	DWT	22
Hình 3.6	FCWT	23
Hình 3.7	CWT Cho ECG	25
Hình 3.8	STFT_CWT	27
Hình 3.9	Độ Phân Giải CWT và STFT	29
Hình 4.1	Flowchart Phân Tách fECG	32
Hình 4.2	Preprocessing	34
Hình 4.3	aECG Chuẩn Hóa	34
Hình 4.4	aECG Sau Khi Lọc Bandpass	35
Hình 4.5	Scalogram Generation	37
Hình 4.6	Wavelet Phụ Thuộc Vào Scale	37
Hình 4.7	CWT Scalogram.	38
Hình 4.8	CWT Spectrogram Chuẩn Hóa	39
Hình 5.1	Cấu Trúc Tổng Thể Của Model.	40
Hình 5.2	LiRA Model.	43
Hình 5.3	Khối Residual (ResBlock) trong mô hình LiRA	44
Hình 5.4	Khối Encoder.	47
Hình 5.5	HybridSTFT_LIRA_Graphviz.	48

Hình 5.6	Khối Decoder.	49
Hình 5.7	LiRA Molde.	51
Hình 5.8	Đầu Ra LiRA Model.	51
Hình 5.9	Tín hiệu fecg sau khi khôi phục	52
Hình 5.10	Tín hiệu fecg sau khi khôi phục	53
Hình 6.1	Tổng quan hiệu suất	57
Hình 7.1	Giấy Chứng Nhận Sinh Viên Nghiên Cứu Khoa Học 2024 - 2025 .	68

DANH MỤC BẢNG BIỂU

Bảng 5.1	Training Parameters	51
Bảng 6.1	Comparison of Evaluation Metrics for Reconstructed Signals . . .	56
Bảng 6.2	Comparison with published methods on the PCDB and ADFECGDB testing sets	58

CHƯƠNG 1. CHƯƠNG MỞ ĐẦU

1.1 Bối cảnh và do chọn đề tài

Việc theo dõi và giám sát sức khỏe tim thai là một yếu tố quan trọng trong việc giảm tỷ lệ tử vong chu sinh và phát hiện sớm các tình trạng bất thường của thai nhi như suy thai, loạn nhịp tim, hoặc thiếu oxy. Theo Tổ chức Y tế Thế giới (WHO), sức khỏe tim thai là một trong những chỉ số quan trọng trong việc chăm sóc bà mẹ và thai nhi, và việc theo dõi thường xuyên có thể giúp giảm thiểu các biến chứng trong quá trình chuyển dạ, đồng thời bảo vệ sức khỏe của thai nhi.

Hiện nay, phương pháp phổ biến trong thực hành lâm sàng để theo dõi nhịp tim thai là sử dụng Cardiotocography (CTG). CTG giúp đo nhịp tim của thai nhi và sự co thắt tử cung, từ đó đánh giá tình trạng tim thai trong suốt quá trình mang thai. Tuy nhiên, CTG chỉ cung cấp thông tin định lượng hạn chế, chủ yếu tập trung vào nhịp tim và các co thắt tử cung mà không thể phân tích chi tiết về hình dạng sóng điện tim. Trong khi đó, việc phân tích hình dạng sóng điện tim thai nhi có giá trị rất lớn trong việc đánh giá chức năng điện sinh lý của tim thai, từ đó giúp chẩn đoán các bất thường tim mạch, phát hiện sớm loạn nhịp và các dấu hiệu suy thai.

Một trong những phương pháp tiềm năng hơn là sử dụng tín hiệu điện tâm đồ thai nhi (fECG), một tín hiệu ghi lại hoạt động điện của tim thai. fECG cung cấp thông tin chi tiết và chính xác hơn về tình trạng tim thai, qua đó hỗ trợ chẩn đoán sớm các rối loạn bẩm sinh và phát hiện sớm nguy cơ suy tim hoặc các vấn đề nghiêm trọng khác. Tuy nhiên, việc thu nhận tín hiệu fECG trực tiếp từ da đầu thai nhi yêu cầu các thủ thuật xâm lấn, chỉ có thể thực hiện trong giai đoạn chuyển dạ và không thể sử dụng rộng rãi trong suốt thai kỳ.

Trong khi đó, một giải pháp không xâm lấn là trích xuất tín hiệu fECG từ điện tâm đồ qua thành bụng mẹ (aECG). Phương pháp này có thể được sử dụng để theo dõi sức khỏe tim thai từ xa (telemonitoring) mà không làm tổn hại đến mẹ và thai nhi. Tuy nhiên, thách thức lớn nhất trong việc trích xuất tín hiệu fECG từ aECG là biên độ tín hiệu fECG rất nhỏ, thường bị chôn lấp dưới mECG (tín hiệu điện tim của mẹ), cùng với sự xuất hiện của nhiều loại nhiễu sinh lý khác như nhiễu từ cơ bắp, nhiễu từ môi trường. Do đó, việc phân tích và tách fECG từ aECG đòi hỏi các kỹ thuật xử lý tín hiệu tiên tiến để giảm thiểu nhiễu và tăng cường khả năng phát hiện tín hiệu fECG.

Đặc biệt, những nghiên cứu gần đây chỉ ra rằng việc tách tín hiệu fECG từ aECG không chỉ là vấn đề khoa học mà còn mang lại giá trị ứng dụng lớn trong việc theo dõi sức khỏe thai nhi và phát hiện sớm các bất thường tim mạch. Phương pháp này giúp bác sĩ có thể theo dõi liên tục tình trạng sức khỏe của thai nhi mà không cần đến các thủ

thuật xâm lấn, đồng thời giúp giảm thiểu các rủi ro cho mẹ và thai nhi.

Do đó, nghiên cứu và phát triển các kỹ thuật xử lý tín hiệu tiên tiến nhằm nâng cao khả năng tách, phát hiện và phân tích tín hiệu fECG là hết sức cần thiết, không chỉ trong bối cảnh cải thiện chất lượng chăm sóc sức khỏe thai nhi mà còn trong việc cung cấp các giải pháp telemonitoring hiệu quả hơn. Đề tài này hướng tới mục tiêu đó thông qua việc ứng dụng các phương pháp phân tích thời–tần hiện đại kết hợp với mô hình học sâu tối ưu hóa cho tín hiệu sinh lý không ổn định.

1.2 Mục tiêu nghiên cứu

Mục tiêu của nghiên cứu này là phát triển mô hình học sâu kết hợp với các phương pháp phân tích thời–tần để tách **tín hiệu điện tâm đồ thai nhi (fECG)** từ **tín hiệu điện tâm đồ qua thành bụng mẹ (aECG)**. Các mục tiêu cụ thể bao gồm:

- Xây dựng mô hình học sâu tự mã hóa (Autoencoder) để tách fECG từ aECG, giảm nhiễu và tối ưu hóa khả năng tách tín hiệu.
- Xây dựng thuật toán CWT (Continuous Wavelet Transform) và ICWT (Inverse Continuous Wavelet Transform) để phân tích và tái tạo tín hiệu fECG.
- Lựa chọn sóng mẹ phù hợp cho CWT để tối ưu hóa khả năng phân tích đặc trưng thời–tần của fECG.
- Đánh giá hiệu quả mô hình qua các chỉ số như SNR (Signal-to-Noise Ratio), RMSE (Root Mean Squared Error), MAPE (Mean Absolute Percentage Error) và khả năng phát hiện đỉnh R.
- So sánh với phương pháp truyền thống như ICA (Independent Component Analysis) và EKF (Extended Kalman Filter) để chứng minh tính ưu việt.
- Đề xuất cải tiến và khả năng ứng dụng thực tiễn trong hệ thống theo dõi từ xa hoặc thiết bị đeo thông minh cho sản phụ.

1.3 Phạm vi và giới hạn nghiên cứu

Đề tài tập trung vào bài toán trích xuất tín hiệu điện tâm đồ thai nhi (fECG) từ tín hiệu hỗn hợp abdominal ECG (aECG) thông qua phương pháp phân tích thời–tần hiện đại kết hợp mô hình học sâu. Mục tiêu là xây dựng một mô hình học sâu xử lý tín hiệu không xâm lấn, có khả năng hoạt động hiệu quả trong môi trường nhiễu cao và phù hợp với ứng dụng thực tiễn.

Phạm vi nghiên cứu cụ thể bao gồm:

- Thu nhận, xử lý và chuẩn hóa tín hiệu aECG từ các nguồn dữ liệu công khai PhysioNet (bộ dữ liệu ADFECGDB, PCDB).
- Áp dụng biến đổi sóng liên tục (Continuous Wavelet Transform – CWT) để biểu diễn tín hiệu dưới dạng miền thời–tần, từ đó tách biệt các đặc trưng fECG với MEGG và nhiễu.
- Thiết kế và huấn luyện mô hình tự mã hóa học sâu (Residual Autoencoder – LiRA) nhằm học và tái tạo đặc trưng fECG trong miền wavelet.
- Xây dựng và triển khai thuật toán khôi phục tín hiệu thời gian từ biểu diễn wavelet thông qua biến đổi ngược (Inverse Continuous Wavelet Transform – iCWT), đảm bảo duy trì cấu trúc sóng ECG và độ chính xác về pha.
- Đánh giá chất lượng tín hiệu fECG khôi phục thông qua các chỉ số định lượng (RMSE, MAPE, SNR) và các tiêu chí lâm sàng như phát hiện đỉnh R.

1.4 Đối tượng nghiên cứu

Đối tượng nghiên cứu của đề tài này là tín hiệu điện tâm đồ thai nhi (fECG) và tín hiệu điện tâm đồ qua thành bụng mẹ (aECG).

Đề tài không đi sâu vào nghiên cứu phần cứng thu nhận tín hiệu, các kỹ thuật y sinh chuyên sâu, hay phân loại bệnh lý. Tuy nhiên, kết quả nghiên cứu có thể là tiền đề cho các hệ thống theo dõi sức khỏe tim thai trong thời gian thực hoặc các thiết bị đeo thông minh.

1.5 Cấu trúc báo cáo

Báo cáo được tổ chức gồm 7 chương như sau:

- **Chương 1 – Mở đầu:** Trình bày tổng quan đề tài, lý do chọn, mục tiêu và phạm vi.
- **Chương 2 – Tổng quan về ECG và fECG:** Phân tích đặc điểm sinh lý, vai trò và các thách thức kỹ thuật.
- **Chương 3 – Cơ sở lý thuyết CWT:** Trình bày lý thuyết về CWT và so sánh với STFT, Stockwell.
- **Chương 4 – Preprocessing aECG:** Mô tả pipeline tiền xử lý, chuyển miền, sinh ảnh và học sâu.
- **Chương 5 – Triển khai LiRA Model:** Mô tả công cụ, dữ liệu và quy trình thực nghiệm.

- **Chương 6 – Kết quả và đánh giá:** Phân tích định lượng và trực quan kết quả trên hai tập dữ liệu.
- **Chương 7 – Thảo luận và hướng phát triển:** So sánh với các phương pháp khác, đánh giá khả năng ứng dụng và định hướng tương lai.

CHƯƠNG 2. Tổng quan về tín hiệu ECG và FmECG

2.1 Giới thiệu tín hiệu ECG cơ bản

2.1.1 Các thành phần của tín hiệu ECG

Tín hiệu điện tâm đồ (ECG - Electrocardiogram) là một loại tín hiệu sinh học quan trọng phản ánh hoạt động điện học của tim. Nó được thu thập bằng cách đặt các điện cực lên bề mặt cơ thể, từ đó ghi nhận sự thay đổi điện thế do hoạt động co bóp của tim gây ra theo thời gian. Một chu kỳ điện tim điển hình bao gồm ba thành phần chính: sóng P, phức bộ QRS, và sóng T. Trong đó, sóng P biểu diễn quá trình khử cực của tâm nhĩ, phức bộ QRS đại diện cho sự khử cực của tâm thất - phần mạnh nhất trong chu kỳ, và sóng T thể hiện quá trình tái cực của tâm thất. Một số trường hợp đặc biệt còn có thể ghi nhận sóng U – một sóng nhỏ theo sau sóng T, có thể liên quan đến sự tái cực muộn của hệ Purkinje hoặc tâm thất.


Các khoảng và đoạn trong chu kỳ ECG cũng mang ý nghĩa sinh lý đặc biệt. Chẳng hạn, khoảng PR (từ đầu sóng P đến đầu sóng QRS) thể hiện thời gian dẫn truyền từ tâm nhĩ đến tâm thất, trong khi đoạn ST thường được dùng để đánh giá nguy cơ thiếu máu cơ tim. Khoảng QT, kéo dài từ đầu QRS đến cuối sóng T, phản ánh thời gian khử cực và tái cực toàn phần của tâm thất. Sự thay đổi về hình dạng, thời gian hoặc biên độ của các thành phần này có thể là dấu hiệu của rối loạn tim mạch.

Theo Addison trong bài tổng quan về wavelet và ECG, việc hiểu rõ các đặc trưng này là nền tảng để áp dụng các phương pháp xử lý tín hiệu như phân tích wavelet nhằm phát hiện và phân loại bất thường tim mạch [1]. Đồng thời, các thuật toán học sâu như CNN hoặc Autoencoder cũng yêu cầu đầu vào là những đặc trưng rõ ràng của các thành phần ECG [2, 3].

2.1.2 Ứng dụng trong chẩn đoán tim mạch

Tín hiệu ECG là công cụ chẩn đoán nền tảng trong lâm sàng tim mạch. Từ các tín hiệu ECG thu thập được, bác sĩ có thể xác định nhiều bệnh lý như loạn nhịp tim (arrhythmia), phì đại tim, block nhĩ-thất, hội chứng QT dài, thiếu máu cơ tim hoặc nhồi máu cơ tim. Ví dụ, đoạn ST chênh lên là dấu hiệu cổ điển của nhồi máu cơ tim cấp, còn sóng P bất thường có thể chỉ ra rung nhĩ hoặc ngoại tâm thu nhĩ [4, 5]. Phức hợp QRS rộng hoặc bất thường có thể liên quan đến block nhánh hoặc hội chứng Wolff-Parkinson-White.

Trong các nghiên cứu gần đây, đặc biệt là với sự phát triển của cảm biến và thiết bị đeo thông minh, ECG không chỉ được sử dụng trong bệnh viện mà còn ứng dụng rộng rãi trong theo dõi bệnh nhân từ xa hoặc chăm sóc sức khỏe liên tục. Nghiên cứu của



Hình 2.1 Hình ảnh tín hiệu ECG với các sóng PQRSTU thể hiện chu trình hoạt động bơm máu của tim. Sóng P phản ánh sự co bóp của tâm nhĩ, phức hợp QRS thể hiện sự co bóp của tâm thất, sóng T là quá trình phục hồi của cơ tim, và sóng U (nếu có) liên quan đến sự tái cực của cơ tim. Các sóng này giúp đánh giá sức khỏe tim mạch và phát hiện các bất thường như loạn nhịp hay suy tim.


Martinek và cộng sự đã đề xuất các phương pháp tối ưu hóa vị trí điện cực trên bụng mẹ để cải thiện tín hiệu ECG thai nhi, hướng tới ứng dụng trong giám sát tim thai không xâm lấn [6]. Ngoài ra, trong [7], tác giả tiến hành so sánh nhiều phương pháp tách tín hiệu tim thai (fECG) từ tín hiệu hỗn hợp thu từ bụng mẹ, cho thấy ECG không chỉ quan trọng trong chẩn đoán mà còn là trung tâm trong các nghiên cứu xử lý tín hiệu y sinh hiện đại.

Sự phát triển của kỹ thuật học sâu như Autoencoder [3], GAN [8], và mạng nơ-ron tích chập (CNN) [9, 2] đã thúc đẩy khả năng khai thác tín hiệu ECG vượt ra ngoài phân tích cổ điển. Việc chuyển đổi tín hiệu ECG thành biểu diễn thời–tần (như CWT hoặc STFT) giúp phát hiện các bất thường có tính động lực học cao mà các phương pháp xử lý thời gian cố định không thể phát hiện được. Việc phân tích trên miền wavelet còn được chứng minh là giúp nâng cao chất lượng phân tích tín hiệu ECG trong nhiều nghiên cứu gần đây [10, 11, 12].

Đặc biệt, tín hiệu fECG thu được từ bụng mẹ có biên độ nhỏ hơn rất nhiều so với tín hiệu ECG của mẹ (mECG), và thường bị nhiễu. Việc trích xuất tín hiệu fECG nhằm hỗ trợ chẩn đoán sớm các vấn đề của thai nhi là một hướng nghiên cứu đầy tiềm năng. Các phương pháp như ICA, PCA, adaptive filtering, CWT, hoặc gần đây là deep learning và hybrid methods đều được nghiên cứu rộng rãi [5, 7, 13].

2.2 Đặc điểm và ý nghĩa lâm sàng của Fetal ECG (FmECG)

2.2.1 Đặc điểm tín hiệu FmECG



Hình 2.2 Hình ảnh mô phỏng cách đo aECG thể hiện các điện cực được gắn trực tiếp lên bề mặt da của người mẹ, thường là vùng bụng, để thu tín hiệu điện tim của thai nhi. Các điện cực này giúp ghi lại các sóng điện tim, tuy nhiên tín hiệu từ thai nhi thường bị lẫn át bởi tín hiệu từ tim mẹ (mECG) và các nhiễu khác, đòi hỏi phải có phương pháp xử lý tín hiệu để tách biệt và phân tích tín hiệu của thai nhi. .

Fetal ECG (FmECG) là tín hiệu điện học phản ánh hoạt động điện của tim thai nhi. Không giống như tín hiệu ECG của người trưởng thành, tín hiệu FmECG có đặc điểm rất đặc thù và đặt ra nhiều thách thức trong việc thu nhận và xử lý. Trước tiên, biên độ của FmECG rất nhỏ, chỉ dao động từ 10–60 microvolt, trong khi tín hiệu ECG của mẹ (mECG) có thể lên đến hàng millivolt, dẫn đến việc tín hiệu của thai nhi thường bị chôn lấp hoàn toàn trong tín hiệu hỗn hợp thu được từ bụng mẹ (AECG) [7, 5]. Thứ hai, nhịp tim của thai nhi cũng cao hơn đáng kể, trung bình từ 120–160 nhịp/phút, so với nhịp tim người lớn trung bình là 60–100 nhịp/phút.


Một điểm đặc trưng khác là hình dạng sóng QRS của FmECG thường ngắn hơn và nhọn hơn, phản ánh tốc độ dẫn truyền điện nhanh qua hệ thống tim mạch chưa trưởng thành. Tuy nhiên, do sự chồng lấn từ mECG, nhiễu cơ (EMG), chuyển động của mẹ, nhiễu từ cảm biến, và biến thiên vị trí thai nhi, sóng FmECG thường bị méo dạng, nhiễu nặng hoặc không quan sát được trực tiếp. Tuy nhiên tín hiệu fecg vẫn giữ cấu trúc các phức bộ đỉnh tim QRS như người trưởng thành được miêu tả trong hình 2.1 [4, 6].

Các nghiên cứu gần đây như của Ziani et al. [10] và Alshebly et al. [11] đã chứng minh rằng việc phân tích FmECG trên miền wavelet liên tục (Continuous Wavelet Transform – CWT) giúp tái hiện rõ hơn các đặc trưng thời–tần tính vi của sóng tim thai, so với phân tích chỉ trong miền thời gian hoặc tần số. Sự thay đổi tần số tim thai theo thời gian – gọi là biến thiên nhịp tim (Fetal Heart Rate Variability – FHRV) – cũng là chỉ

số rất quan trọng trong đánh giá sức khỏe thai nhi và có thể được trích xuất từ FmECG khi tín hiệu đủ sạch [14, 5].

Đặc điểm dễ bị che khuất và độ nhiễu cao khiến cho việc tách FmECG trở thành một bài toán đầy thách thức. Nhiều nghiên cứu đã đề xuất sử dụng các kỹ thuật tách tín hiệu mù như ICA [15], PCA, adaptive filtering [5], hoặc các mô hình học sâu như autoencoder [3], W-Net [2], hay GAN [13, 8] để phục hồi FmECG. Đặc biệt, các phương pháp kết hợp với wavelet hoặc biểu diễn phổ thời–tần như De-shape STFT, CWT đã cho thấy hiệu quả rõ rệt trong việc tái hiện tín hiệu tim thai có hình dạng chuẩn [16, 12].

2.2.2 Ý nghĩa và ứng dụng lâm sàng của FmECG



Hình 2.3 Hình ảnh Doppler màu siêu âm thể hiện phương pháp đo chuyển đạo bơm máu của tim, sử dụng sóng siêu âm để quan sát và đánh giá dòng chảy máu trong các mạch máu. Doppler màu siêu âm giúp hiển thị tốc độ và hướng di chuyển của máu thông qua các màu sắc khác nhau, từ đó cung cấp thông tin quan trọng về chức năng tim và các vấn đề liên quan đến lưu thông máu.

Tín hiệu FmECG mang lại giá trị lâm sàng đặc biệt trong chẩn đoán và theo dõi thai kỳ. So với các phương pháp truyền thống như siêu âm Doppler hay đo tim thai gián tiếp bằng CTG (Cardiotocography), FmECG cung cấp thông tin chính xác hơn về hoạt động điện của tim thai và có thể phát hiện được nhiều bất thường mà các phương pháp khác bỏ sót.

Một trong những ứng dụng quan trọng nhất của FmECG là phát hiện sớm các rối loạn nhịp tim bẩm sinh như block nhĩ–thất thai nhi, ngoại tâm thu, hoặc hội chứng QT dài. Đây là những dấu hiệu có thể dẫn đến rối loạn huyết động nghiêm trọng hoặc đột tử thai nhi nếu không được phát hiện và can thiệp kịp thời [4, 3]. FmECG cũng giúp theo dõi tình trạng thiếu oxy, stress tim, và đáp ứng của thai với cơn co tử cung – đặc biệt trong giai đoạn chuyển dạ.


Việc theo dõi fECG mang lại nhiều lợi ích quan trọng trong y học hiện đại. Thông

qua phân tích chỉ số FHRV (Fetal Heart Rate Variability), ta có thể đánh giá hệ thần kinh tự chủ (ANS) của thai nhi, từ đó phát hiện sớm các dấu hiệu nguy cơ như phát triển chậm trong tử cung (IUGR), rối loạn thần kinh thai hoặc thiếu oxy. Các chỉ số FHRV giảm có thể chỉ ra tình trạng thiếu oxy, rối loạn thần kinh hoặc các vấn đề tim mạch, giúp bác sĩ can thiệp kịp thời. Theo dõi fECG cũng hỗ trợ giám sát sức khỏe thai nhi từ xa, thông qua các thiết bị đeo thông minh hoặc hệ thống theo dõi từ xa, giúp giảm thiểu nguy cơ và cải thiện chất lượng chăm sóc sản phụ. [5].

Ngoài ra, với sự phát triển của công nghệ thiết bị đeo, FmECG còn được ứng dụng trong các hệ thống theo dõi liên tục thai nhi tại nhà, giúp giảm áp lực cho hệ thống y tế và nâng cao chất lượng chăm sóc tiền sản ở những vùng khó tiếp cận [2, 8]. Việc sử dụng mô hình học sâu như GAN, autoencoder, hoặc mạng hồi tiếp để tách tín hiệu FmECG từ dữ liệu AECG đã mở ra triển vọng rất lớn cho các hệ thống theo dõi từ xa, hoạt động thời gian thực [13, 3, 12].

Hơn nữa, trong các thử nghiệm lâm sàng, tín hiệu FmECG còn có thể được đồng bộ hóa với các cảm biến chuyển động thai, cảm biến oxy, hoặc dữ liệu Doppler để cung cấp một hệ sinh thái theo dõi thai toàn diện và tự động hoá.

2.2.3 *Nhiều và khó khăn trong việc phân biệt tín hiệu mẹ và tín hiệu thai nhi*



Hình 2.4 aECG thu từ bụng mẹ chứa tín hiệu điện tim từ cả mẹ (mECG) và thai nhi (fECG), cùng với các nhiễu (noise) từ môi trường xung quanh. Tín hiệu aECG bao gồm ba thành phần chính: fECG, là tín hiệu từ tim thai nhi; mECG, là tín hiệu từ tim mẹ; và noise, là các nhiễu không mong muốn ảnh hưởng đến tín hiệu, khiến cho việc tách biệt và phân tích fECG trở nên khó khăn và cần phải có các phương pháp xử lý tín hiệu đặc biệt.

Việc trích xuất tín hiệu Fetal ECG (FmECG) từ tín hiệu điện tim hỗn hợp thu được ở bụng mẹ (Abdominal ECG – AECG) là một trong những thách thức lớn nhất trong lĩnh vực xử lý tín hiệu y sinh. Nguyên nhân chính đến từ bản chất phức tạp của tín hiệu hỗn hợp: FmECG bị lẫn sâu trong mECG (Maternal ECG), đồng thời chịu ảnh hưởng mạnh mẽ từ nhiễu sinh lý và nhiễu môi trường. Trong thực tế, mECG có biên độ lớn hơn FmECG từ 10 đến 100 lần, thường dao động trong khoảng 0.5–1.5 mV, trong khi FmECG chỉ khoảng 10–60 μ V [7, 5]. Điều này khiến FmECG dễ bị che lấp hoàn toàn,

đặc biệt là tại các thời điểm QRS của mẹ và thai trùng nhau.

Không chỉ khác biệt về biên độ, các thành phần tín hiệu này còn có hình thái tương tự nhau: cả mECG và FmECG đều có sóng P, phức bộ QRS và sóng T, với sự khác biệt nhỏ về hình dạng và độ rộng. Điều này dẫn đến sự nhầm lẫn trong quá trình phân tích nếu không có biện pháp xử lý đặc biệt. Các nghiên cứu đã chỉ ra rằng, hiện tượng trùng pha giữa QRS của mẹ và thai là nguyên nhân chính gây thất bại trong tách tín hiệu bằng các phương pháp truyền thống [4].

Hơn nữa, AECG thường chứa các thành phần nhiễu đa dạng và khó kiểm soát, bao gồm: nhiễu cơ điện (EMG) từ cơ bụng, nhiễu do cử động của mẹ và thai nhi, nhiễu do hô hấp, và tín hiệu giả từ môi trường. Những yếu tố này tạo ra phổ tín hiệu trùng lặp với FmECG và làm cho việc lọc nhiễu trở nên phức tạp, đặc biệt khi các thành phần này không ổn định hoặc thay đổi nhanh theo thời gian [6].

Ngoài ra, các yếu tố sinh học như chỉ số BMI của mẹ, độ dày mô mỡ, tư thế nằm, tuần thai, hoặc vị trí và tư thế của thai nhi cũng ảnh hưởng mạnh đến chất lượng tín hiệu thu được. Ví dụ, khi thai nhi quay lưng ra ngoài, tín hiệu FmECG thường rõ hơn so với khi quay mặt ra phía bụng mẹ. Martinek và cộng sự đã chứng minh rằng vị trí điện cực không tối ưu có thể khiến tín hiệu FmECG gần như biến mất hoàn toàn hoặc bị sai lệch nghiêm trọng về hình dạng [6].

Tất cả những yếu tố này kết hợp lại tạo nên một môi trường tín hiệu phức tạp, đa nguồn, phi tuyến và phi định trạm – làm cho việc tách FmECG trở thành một bài toán ngược dưới điều kiện nghiêm ngặt về nhiễu và suy giảm biên độ. Do đó, các phương pháp truyền thống thường chỉ thành công trong các tình huống lý tưởng và không đủ linh hoạt để áp dụng trong thực tế.

2.3 Các phương pháp đã được nghiên cứu (ICA, Kalman, v.v.)

2.3.1 Các phương pháp truyền thống và khuyết điểm của chúng

Trong hai thập kỷ qua, nhiều phương pháp truyền thống đã được phát triển nhằm tách FmECG từ tín hiệu AECG, trong đó tiêu biểu là các kỹ thuật lọc thích nghi, phân tích thành phần mùa, và biến đổi miền thời–tần.

Lọc thích nghi (Adaptive Filtering) là một trong những phương pháp cổ điển, thường sử dụng thuật toán LMS hoặc RLS để triệt tiêu tín hiệu mECG khỏi AECG bằng cách tận dụng một kênh mECG tham chiếu (thường thu từ ngực mẹ). Nguyên lý là huấn luyện bộ lọc thích nghi để ước lượng mECG trong AECG, sau đó trừ đi khỏi tín hiệu đầu vào để làm lộ ra FmECG. Dù có hiệu quả trong điều kiện phòng thí nghiệm, phương pháp này đòi hỏi thêm phần cứng và khó áp dụng trong hệ thống đeo hoặc giám sát tại nhà, nơi chỉ có một đầu vào [17, 6]. Ngoài ra, giả định về quan hệ tuyến tính và ổn định giữa mECG ở hai kênh đầu vào không luôn được đảm bảo trong điều kiện thực tế.

Phân tích thành phần độc lập (ICA) và **phân tích thành phần chính (PCA)** thuộc nhóm các kỹ thuật **tách tín hiệu mù (Blind Source Separation – BSS)**. ICA tìm cách tách các nguồn tín hiệu độc lập thống kê bằng cách cực đại hoá độ phi Gaussian, trong khi PCA tìm các hướng phương sai lớn nhất. Cả hai yêu cầu ít nhất 2–3 kênh đầu vào khác nhau, điều này hạn chế khả năng áp dụng trong hệ thống đơn kênh. ICA đặc biệt nhạy cảm với nhiễu và trùng pha, trong khi PCA không phân biệt tốt các thành phần tín hiệu có cùng phương sai nhưng khác đặc trưng lâm sàng [5, 15].

Biến đổi wavelet rời rạc (DWT) và **liên tục (CWT)** cũng được áp dụng để xử lý FmECG dựa trên các đặc trưng thời–tần. Cụ thể, DWT trích xuất tín hiệu ở các mức phân giải khác nhau theo thang thời gian, giúp tách các thành phần tần số thấp như FmECG. Tuy nhiên, hiệu quả của DWT phụ thuộc mạnh vào việc chọn đúng loại wavelet mẹ và số mức decomposition phù hợp. Ngược lại, CWT cung cấp phân giải cao và liên tục, lý tưởng cho phân tích FmECG không định trạm, nhưng chi phí tính toán cao khiến khó áp dụng trong thời gian thực [1, 10, 11].


Một số kỹ thuật nâng cao khác như **Ensemble Empirical Mode Decomposition (EEMD)** phân tách tín hiệu thành các thành phần dao động nội tại (IMFs), tuy có thể thích nghi tốt với tín hiệu không tuyến tính, nhưng dễ xảy ra hiện tượng trộn mode và phụ thuộc mạnh vào chiến lược thresholding [18]. Bên cạnh đó, phương pháp **De-shape STFT** [16] kết hợp phân tích tần số và hình dạng sóng nhằm phục hồi FmECG, nhưng lại yêu cầu xử lý hậu kỳ phức tạp để tái cấu trúc tín hiệu đầu ra.

Nhìn chung, các phương pháp truyền thống thường dựa vào các giả định mạnh (độc lập thống kê, tuyến tính, ổn định) và ít có khả năng học được các đặc trưng phức tạp từ dữ liệu thực. Điều này dẫn đến hiệu suất không ổn định và độ tổng quát kém khi triển khai ngoài phòng thí nghiệm. Những hạn chế này đã mở đường cho các phương pháp hiện đại hơn như học sâu, trong đó các mô hình như autoencoder, W-Net, hoặc conditional GAN được thiết kế để học trực tiếp ánh xạ từ AECG sang FmECG, không cần giả định mạnh về cấu trúc tín hiệu [3, 8, 13] – sẽ được thảo luận ở các chương tiếp theo.

2.3.2 Phương pháp phân tách tín hiệu dựa trên ICA (Independent Component Analysis)

Phân tích thành phần độc lập (Independent Component Analysis – ICA) là một trong những phương pháp nền tảng trong bài toán tách tín hiệu mù (Blind Source Separation – BSS) và đã được áp dụng rộng rãi trong trích xuất FmECG từ tín hiệu hỗn hợp AECG. ICA giả định rằng tín hiệu hỗn hợp là sự kết hợp tuyến tính của nhiều nguồn tín hiệu độc lập thống kê, và nhiệm vụ của thuật toán là tìm một ma trận tách tối ưu để khôi phục lại các thành phần gốc độc lập đó [5, 15].

Một trong những ưu điểm chính của ICA là khả năng tách tín hiệu mà không cần



Hình 2.5 Kết quả fECG từ phương pháp phân tích thành phần độc lập (ICA) cho thấy phương pháp này có khả năng phân tách tín hiệu fECG khỏi mECG khá tốt. Tuy nhiên, vẫn còn một số nhiễu tồn tại và quá trình phân tách fECG khỏi mECG chưa hoàn toàn chính xác, do ảnh hưởng của các yếu tố nhiễu khác và sự phức tạp trong việc tách biệt hai tín hiệu này trong điều kiện thực tế.

thông tin a priori về hình dạng hay thời gian xuất hiện. Điều này đặc biệt hữu ích trong môi trường không có mô hình chính xác cho mECG hay FmECG. Tuy nhiên, ICA có nhiều ràng buộc: đầu tiên, nó yêu cầu số kênh đầu vào (AECG) ít nhất phải bằng số nguồn cần tách, tức là cần thiết lập hệ thống thu đa kênh, điều này không luôn khả thi trong ứng dụng thực tiễn như theo dõi tại nhà hoặc thiết bị đeo [7].

Thêm vào đó, giả định về tính độc lập thống kê giữa mECG và FmECG không luôn đúng, đặc biệt là tại các thời điểm trùng pha hoặc khi các tín hiệu có dạng sóng tương tự nhau. Trong những tình huống này, ICA có thể không tách được đúng FmECG mà chỉ đưa ra tổ hợp tuyến tính của các thành phần ban đầu, gây nhiễu đầu ra. Ngoài ra, ICA cũng rất nhạy cảm với nhiễu không mong muốn (chẳng hạn như chuyển động hoặc tín hiệu giả), khiến tín hiệu đầu ra kém ổn định [6].

2.3.3 Phương pháp Kalman Filter và ứng dụng trong tín hiệu y sinh

Bộ lọc Kalman là một kỹ thuật lọc tối ưu trong miền thời gian, sử dụng mô hình trạng thái để ước lượng biến ẩn từ dữ liệu quan sát bị nhiễu. Trong lĩnh vực sinh y, Kalman Filter thường được dùng để dự đoán và theo dõi tín hiệu ECG theo thời gian thực. Nguyên lý hoạt động của nó là duy trì một ước lượng trạng thái và ma trận hiệp phương sai lỗi, sau đó cập nhật liên tục khi có dữ liệu mới [6, 5].

Khi áp dụng vào tách FmECG, bộ lọc Kalman được dùng để mô hình hóa động học của mECG, cho phép ước lượng và loại bỏ tín hiệu mẹ ra khỏi AECG, từ đó làm lộ tín hiệu thai nhi. Ưu điểm nổi bật của phương pháp này là khả năng thích ứng thời gian thực và hiệu quả cao trong môi trường có mô hình động học rõ ràng. Ngoài ra, Kalman cũng phù hợp với hệ thống thu đơn kênh – không giống như ICA yêu cầu đa kênh [4].

Tuy nhiên, hạn chế lớn của bộ lọc Kalman là sự phụ thuộc vào mô hình trạng thái chính xác. Trong thực tế, các tín hiệu ECG – đặc biệt là FmECG – thường có sự biến thiên không tuyến tính, phi định trạm, và khó mô tả chính xác bằng mô hình tuyến tính đơn giản. Vì vậy, nếu mô hình không đủ chính xác, Kalman Filter có thể đưa ra ước lượng sai lệch hoặc bỏ sót tín hiệu quan trọng. Hơn nữa, hiệu suất Kalman thường suy giảm mạnh trong điều kiện có nhiều đột biến hoặc chuyển động mạnh, điều thường xuyên xảy ra trong môi trường lâm sàng thực tế.

2.4 Lựa Chọn Phương Pháp

Như đã phân tích, các phương pháp truyền thống như Lọc thích nghi (Adaptive Filtering), Phân tích thành phần độc lập (ICA), và Bộ lọc Kalman đã được ứng dụng để tách FmECG từ tín hiệu aECG. Tuy nhiên, những phương pháp này gặp phải nhiều hạn chế, đặc biệt khi tín hiệu aECG chứa rất nhiều nhiễu và fECG của thai nhi có biên độ rất nhỏ, dễ bị chồng lấp với mECG của mẹ. Các phương pháp như ICA và Kalman Filter yêu cầu nhiều kênh đầu vào và giả định về tính tuyến tính của tín hiệu, điều này không phải lúc nào cũng đúng trong môi trường thực tế. Thêm vào đó, chúng rất nhạy cảm với nhiễu và sự thay đổi tín hiệu, gây khó khăn trong việc tách tín hiệu chính xác.

Vì những lý do trên, trong phạm vi nghiên cứu này, CWT (Continuous Wavelet Transform) được chọn là phương pháp chủ đạo để xử lý tín hiệu fECG. CWT sẽ được áp dụng để biến tín hiệu aECG trong miền thời gian thành tín hiệu 2D, với trục thời gian và tần số, từ đó tạo ra một scalogram (biểu diễn thời gian-tần số) của tín hiệu aECG. Sự biến đổi này cho phép tách biệt thông tin fECG và mECG trong không gian tần số và thời gian, giúp phân tích các đặc trưng của tín hiệu fECG bị chồng lấp trong tín hiệu mECG.

Với những đặc điểm ưu việt này, CWT được chọn là phương pháp tối ưu trong nghiên cứu này để giải quyết bài toán tách fECG từ aECG, đặc biệt trong môi trường có nhiễu nhiều và tín hiệu fECG rất nhỏ.

CHƯƠNG 3. Cơ sở lý thuyết về Sóng liên tục (CWT)

3.1 Giới thiệu về Sóng liên tục (CWT)

Biến đổi Sóng Liên tục (Continuous Wavelet Transform - CWT) là một công cụ mạnh mẽ trong phân tích tín hiệu thời–tần, cho phép phát hiện các đặc trưng cục bộ của tín hiệu không định trạm. CWT đặc biệt hữu ích trong phân tích tín hiệu sinh học như ECG (Electrocardiogram) và FmECG (Fetal ECG), nơi tín hiệu thay đổi theo thời gian và có các đặc trưng tần số không ổn định. Khác với Fourier Transform (FT), vốn chỉ thể hiện thông tin trong miền tần số tổng thể, CWT cung cấp khả năng phân giải đa thang (multi-scale) và cho phép xác định các đặc trưng của tín hiệu tại từng thời điểm cụ thể [19].

Trong khi FT và Short-Time Fourier Transform (STFT) cung cấp một phân tích tín hiệu tổng thể trong miền tần số hoặc qua cửa sổ cố định, CWT sử dụng sóng mẹ (mother wavelet) co giãn và dịch chuyển để phân tích tín hiệu trong các khoảng thời gian và tần số khác nhau [19]. Điều này giúp CWT vượt trội trong việc phân tích các tín hiệu không ổn định hoặc có sự thay đổi nhanh về đặc tính, như trong tín hiệu ECG và FmECG, nơi các đặc trưng cần được phát hiện và phân tách ngay cả khi tín hiệu bị nhiễu hoặc có độ biến động cao [1].

Một trong những đặc điểm nổi bật của CWT là khả năng cung cấp độ phân giải thời gian và tần số khác nhau cho các thành phần tần số khác nhau trong tín hiệu. Điều này cho phép CWT phân tích tín hiệu ở nhiều cấp độ chi tiết khác nhau, từ các dao động nhanh cho đến các thay đổi chậm trong tín hiệu [1].

3.2 Nguyên lý toán học của CWT

Biến đổi Sóng Liên tục (Continuous Wavelet Transform - CWT) là một phương pháp mạnh mẽ trong phân tích tín hiệu thời–tần, giúp phát hiện các đặc trưng cục bộ của tín hiệu không định trạm. Cơ sở toán học của CWT liên quan đến việc tính toán mức độ tương quan giữa tín hiệu gốc và các phiên bản co giãn (scale) và dịch chuyển (time shift) của sóng mẹ (mother wavelet).

3.2.1 Định nghĩa CWT và công thức

Công thức toán học cơ bản của CWT cho tín hiệu $x(t)$ trong miền thời gian được định nghĩa như sau:

$$\mathcal{W}_x(a, b) = \int_{-\infty}^{+\infty} x(t) \cdot \frac{1}{\sqrt{|a|}} \psi\left(\frac{t-b}{a}\right) dt \quad (3.1)$$

Trong đó:

- $x(t)$ là tín hiệu gốc cần phân tích,
- $\psi(t)$ là sóng mẹ (**mother wavelet**), có tích phân bằng 0 và năng lượng hữu hạn,
- $a \in R^+$ là hệ số **scale**, điều khiển mức độ co giãn (nghịch đảo với tần số),
- $b \in R$ là hệ số **dịch thời gian**, điều khiển vị trí phân tích tín hiệu tại thời điểm b .

Hệ số $1/\sqrt{|a|}$ đảm bảo rằng năng lượng của sóng mẹ không thay đổi khi thay đổi scale. Điều này có nghĩa là dù bạn thay đổi mức độ co giãn (scale), năng lượng của sóng mẹ vẫn không thay đổi, giúp giữ cho các hệ số CWT đồng nhất về mặt năng lượng [19].

CWT có thể được xem như sự chiếu tín hiệu gốc lên một tập hợp các hàm cơ sở $\psi_{a,b}(t) = \frac{1}{\sqrt{|a|}} \psi\left(\frac{t-b}{a}\right)$, từ đó ánh xạ tín hiệu $x(t)$ sang một mặt phẳng hai chiều (a, b) , nơi a và b đại diện cho scale và dịch thời gian. Điều này cho phép **CWT** thể hiện thông tin của tín hiệu trong cả hai miền thời gian và tần số cùng một lúc.

3.2.2 Phương trình tích phân liên tục

Công thức trên là biểu diễn liên tục của CWT, trong đó phép tích phân chập giữa tín hiệu $x(t)$ và sóng mẹ ψ tại từng scale a và dịch chuyển b được tính. Phương trình này phản ánh mức độ tương quan giữa tín hiệu và các phiên bản co giãn và dịch chuyển của sóng mẹ.

Ý nghĩa của các tham số: - **Sóng mẹ** (ψ) đóng vai trò quyết định trong việc phân tích tín hiệu ở các độ phân giải khác nhau. Các sóng mẹ như Morlet hoặc Mexican Hat có các đặc điểm khác nhau và được chọn tùy theo tính chất tín hiệu cần phân tích (ví dụ, sóng Morlet phù hợp để phân tích các tín hiệu có đặc trưng điều hòa). - **Hệ số scale** (a) điều khiển độ rộng của sóng mẹ, có tác dụng điều chỉnh độ phân giải của tín hiệu trong miền tần số. Hệ số này quyết định cách thức sóng mẹ sẽ co giãn hay co lại khi phân tích tín hiệu. - **Hệ số dịch chuyển** (b) điều khiển vị trí phân tích trong thời gian. Khi thay đổi b , chúng ta có thể phân tích tín hiệu tại các thời điểm khác nhau.

3.2.3 Xấp xỉ rời rạc trong tính toán CWT

Khi làm việc với tín hiệu rời rạc, công thức tích phân liên tục trên (3.1) cần phải được xấp xỉ bằng tổng hữu hạn. Công thức rời rạc cho **CWT** là:


$$\mathcal{W}_x(a, b) \approx \sum_{n=0}^{N-1} x[n] \cdot \frac{1}{\sqrt{|a|}} \psi\left(\frac{n-b}{a}\right) \quad (3.2)$$

Ở đây, thay vì tích phân trên toàn bộ miền thời gian, ta thực hiện phép tính tổng trên các giá trị rời rạc của tín hiệu $x[n]$. Điều này cho phép tính toán **CWT** cho các tín

hiệu số hoặc tín hiệu rời rạc mà không yêu cầu tính toán liên tục. Sự thay đổi từ tích phân sang tổng này là cần thiết khi làm việc với các dữ liệu rời rạc trong các ứng dụng thực tế như phân tích tín hiệu ECG hoặc FmECG.

Ý nghĩa: Hệ số $\mathcal{W}_x(a, b)$ trong công thức rời rạc là mức độ tương quan giữa tín hiệu $x[n]$ và sóng mẹ co giãn tại scale a và dịch tại vị trí b . Công thức này cho phép ta tính toán **CWT** cho các tín hiệu số, đồng thời bảo toàn được các đặc trưng thời gian và tần số của tín hiệu.

3.2.4 *Mối quan hệ giữa scale và tần số*



Hình 3.1 (a) Morlet Wavelet (b) Tần số tại wavelet tương ứng .

Mối quan hệ giữa hệ số scale a và tần số được thể hiện trong công thức dưới đây, giúp chuyển đổi từ miền scale sang miền tần số giả:

$$f = \frac{f_c \cdot f_s}{a} \quad (3.3)$$

Trong đó:

- f là tần số giả (pseudo-frequency) liên kết với scale a ,
- f_c là tần số trung tâm của sóng mẹ $\psi(t)$,
- f_s là tần số lấy mẫu của tín hiệu.


Công thức (3.3): Cho biết mối quan hệ này cho phép quy đổi giữa scale và tần số thực, giúp ta hiểu được cách **CWT** điều chỉnh độ phân giải tần số khi thay đổi giá trị của scale. Cụ thể, khi a giảm, tần số giả f sẽ tăng, điều này có nghĩa là CWT đang phân tích tín hiệu ở độ phân giải tần số cao hơn, rất hữu ích trong việc phát hiện các dao động

nhANH (chẳng hạn như sóng R trong ECG). Ngược lại, khi a tăng, tần số giả giảm, giúp phân tích các đặc trưng chậm hơn trong tín hiệu.

3.3 Các loại Sóng mẹ (Mother Wavelets)

Sóng mẹ (**mother wavelet**) là một yếu tố quan trọng trong việc thực hiện CWT, vì nó quyết định đặc tính phân giải của phép biến đổi đối với các tín hiệu cần phân tích. Trong CWT, sóng mẹ được sử dụng để phân tích tín hiệu theo các tỉ lệ (scaling) và dịch chuyển (translation). Việc lựa chọn sóng mẹ phù hợp là một bước quan trọng trong quá trình phân tích vì nó ảnh hưởng trực tiếp đến khả năng phát hiện các đặc trưng của tín hiệu.

3.3.1 Các loại Sóng mẹ phổ biến



Hình 3.2 Morlet Wavelet là một wavelet thực, có dạng sóng kết hợp giữa một sóng hình sin và một hàm Gaussian. Sóng Morlet thực có đặc điểm là chỉ sử dụng phần thực của sóng, khác với các wavelet phức có cả phần thực và ảo. Điều này giúp Morlet Wavelet dễ dàng ứng dụng trong các tín hiệu thực tế, như tín hiệu ECG, để phân tích và nhận diện các đặc trưng tần số thay đổi theo thời gian. Nhờ tính chất này, nó thường được sử dụng trong các ứng dụng phân tích thời gian và tần số, đặc biệt là trong các tín hiệu không ổn định.

Có nhiều loại sóng mẹ được sử dụng trong CWT, mỗi loại có những đặc tính khác nhau, phù hợp với những bài toán phân tích tín hiệu khác nhau. Dưới đây là một số sóng mẹ phổ biến:

1. **Morlet Wavelet:** Morlet wavelet là một trong những sóng mẹ phổ biến nhất trong CWT, đặc biệt là trong các ứng dụng phân tích tín hiệu sinh học như ECG và FmECG. Morlet wavelet là một sóng phức, được tạo ra bằng cách nhân sóng hình sin với một hàm Gaussian. Công thức của Morlet wavelet là:

$$\psi(t) = \pi^{-\frac{1}{4}} \cdot e^{j2\pi f_0 t} \cdot e^{-t^2/2} \quad (3.4)$$

Sóng Morlet có tính phân giải tần số cao, giúp nhận diện các đặc trưng tần số trong tín hiệu như sóng R trong ECG, đặc biệt khi các thành phần tín hiệu có tần số điều hòa [1, 20].

2. Mexican Hat Wavelet (Ricker Wavelet): Mexican Hat wavelet là đạo hàm bậc hai của hàm Gaussian, có dạng thực và đối xứng. Nó có thể được sử dụng để phát hiện các điểm chuyển đổi (đỉnh/phức hợp) trong tín hiệu, như phức bộ QRS trong tín hiệu ECG. Công thức của Mexican Hat wavelet là:

$$\psi(t) = (1 - t^2) \cdot e^{-t^2/2} \quad (3.5)$$

Mexican Hat rất hiệu quả trong việc phát hiện các dao động nhanh và sắc nét trong tín hiệu, đặc biệt trong việc nhận diện các biên độ nhọn, như các phức bộ QRS.

3. Haar Wavelet: Haar wavelet là sóng mẹ đơn giản nhất và cũng là một trong những loại sóng mẹ đầu tiên được sử dụng trong lý thuyết wavelet. Nó có dạng bậc thang và được sử dụng trong các ứng dụng như nhận diện biên trong các tín hiệu có sự thay đổi đột ngột. Haar wavelet rất hiệu quả khi phân tích các tín hiệu có sự thay đổi nhanh trong thời gian.

4. Paul Wavelet: Paul wavelet là một sóng mẹ thực không đối xứng, thích hợp cho phân tích tín hiệu có biên độ nhỏ và dao động bất đối xứng, như sóng P hoặc sóng T trong ECG. Paul wavelet có khả năng phân giải tần số tốt và được sử dụng trong những ứng dụng cần phân tích các tín hiệu phi điều hòa hoặc bất đối xứng.

5. Gaussian Wavelet: Sóng mẹ Gaussian có dạng hàm Gaussian và là một lựa chọn phổ biến cho các tín hiệu có nhiễu thấp và cấu trúc điều hòa. Gaussian wavelet có khả năng phân giải tần số rất tốt và có thể được sử dụng trong các ứng dụng cần phân tích các tín hiệu có độ biến đổi thấp.

3.3.2 Tính chất của Sóng mẹ

Một sóng mẹ trong CWT phải có một số tính chất quan trọng để đảm bảo rằng phép biến đổi có thể thực hiện được và kết quả phân tích là chính xác:


1. Khả năng địa phương hóa trong miền thời gian và tần số: Sóng mẹ cần phải có khả năng địa phương hóa tốt, tức là có thể nhận diện tín hiệu trong một khoảng thời gian ngắn mà không làm mất thông tin tần số. Điều này rất quan trọng khi phân tích các tín hiệu không ổn định hoặc có thay đổi nhanh về đặc trưng, như trong tín hiệu ECG hoặc FmECG.

2. **Năng lượng hữu hạn:** Sóng mẹ phải có năng lượng hữu hạn, nghĩa là tích phân của bình phương sóng mẹ phải hội tụ. Điều này đảm bảo rằng phép biến đổi **CWT** có thể được thực hiện mà không gặp phải các vấn đề về hội tụ hoặc các hiệu ứng không mong muốn khi tín hiệu có độ dài vô hạn.

3. **Khả năng phân giải theo tỷ lệ:** Tùy vào hệ số scale a , sóng mẹ có thể cung cấp độ phân giải khác nhau trong miền tần số và thời gian. Sóng mẹ phải có khả năng phân giải tốt ở cả các tần số thấp (cho các thành phần chậm trong tín hiệu) và tần số cao (cho các biến động nhanh).

4. **Tính đối xứng và phi đối xứng:** Một số sóng mẹ, như Mexican Hat, có tính đối xứng trong miền thời gian, trong khi các sóng mẹ khác, như Paul wavelet, có tính phi đối xứng. Tính đối xứng này có ảnh hưởng đến việc nhận diện các đặc trưng của tín hiệu, ví dụ như phân biệt các biên độ và dao động.

3.3.3 Lý do chọn Mexh wavelet



Hình 3.3 thể hiện Mexican Hat Wavelet, một loại sóng mẹ trong phân tích wavelet. Mexican Hat Wavelet, hay còn gọi là Ricker Wavelet, có hình dạng giống như một chiếc mũ và được sử dụng để phân tích tín hiệu với độ phân giải cao trong cả miền thời gian và tần số. Sóng mẹ này có đặc điểm là có một đỉnh ở trung tâm và các cánh xung quanh, giúp nhận diện sự thay đổi nhanh trong tín hiệu, đặc biệt trong các tín hiệu có sự biến đổi mạnh mẽ hoặc các đặc trưng không ổn định.

Việc lựa chọn sóng mẹ (mother wavelet) phù hợp là một yếu tố then chốt trong biến đổi sóng liên tục (CWT) để trích xuất tín hiệu fECG. Trong nghiên cứu này, hàm sóng mẹ Mexican Hat (Mexh) được chọn vì những lý do sau:

- **Cấu trúc tương đồng với QRS:** Hàm Mexican Hat là đạo hàm bậc hai của hàm Gaussian, có dạng xung đối xứng và sắc nét, rất giống với hình dạng của phức hợp QRS trong ECG. Điều này giúp nó dễ dàng bắt được các đặc trưng biên độ lớn, biến đổi nhanh của fECG [1].
- **Tập trung năng lượng tốt tại các scale trung bình:** Mexh có khả năng tập trung năng lượng tại một dải tần cụ thể, phù hợp với phổ tần số chính của fECG (10–60

Hz). Nhờ đó, các thành phần fECG nổi bật lên rõ ràng so với nhiễu nền hoặc thành phần MECG [21].

- **Được sử dụng hiệu quả trong các nghiên cứu trước:** Các công trình trước đây đã chứng minh rằng Mexican Hat là một trong những sóng mẹ hiệu quả nhất khi áp dụng cho tín hiệu sinh lý, đặc biệt là khi xử lý tín hiệu ECG có biên độ thấp như fECG [10]. Khả năng phát hiện biên (edge detection) của Mexh giúp tách biệt rõ các điểm chuyển pha – đặc điểm quan trọng trong phát hiện vị trí R của tim thai.
- **Ưu thế về hiệu quả tính toán:** So với các sóng mẹ phức tạp hơn như Morlet hoặc complex Gaussian, Mexh có dạng đơn thực và không yêu cầu các thao tác xử lý phức tạp trong miền tần số, giúp giảm đáng kể thời gian tính toán trong quá trình biến đổi CWT, đặc biệt hữu ích khi áp dụng trên tập dữ liệu lớn.

Với các đặc điểm trên, Mexican Hat được xem là lựa chọn tối ưu cho quá trình phân tích thời–tần của tín hiệu fECG trong luận văn này.


3.4 Ưu điểm của CWT

Biến đổi Sóng Liên tục (CWT) mang lại nhiều ưu điểm vượt trội so với các phương pháp phân tích tín hiệu khác, đặc biệt trong việc xử lý các tín hiệu không ổn định, thay đổi theo thời gian và tần số. Cụ thể, CWT cung cấp khả năng phân giải cao trong cả hai miền thời gian và tần số, điều này giúp phân tích các đặc trưng tín hiệu ở các mức độ chi tiết khác nhau. Dưới đây là một số ưu điểm nổi bật của **CWT**.

3.4.1 Phân giải cao trong cả thời gian và tần số

Một trong những ưu điểm nổi bật của CWT là khả năng cung cấp phân giải cao đồng thời trong cả hai miền thời gian và tần số. Trong khi các phương pháp phân tích truyền thống như Fourier Transform (FT) hoặc Short-Time Fourier Transform (STFT) chỉ cho phép phân tích tín hiệu trong một miền duy nhất (tần số hoặc thời gian), CWT cho phép phân tích tín hiệu trong cả hai miền này một cách đồng thời và linh hoạt. Cụ thể, CWT có thể cung cấp phân giải thời gian tốt ở các tần số cao và phân giải tần số tốt ở các tần số thấp, điều này giúp phân tích chi tiết các đặc trưng tín hiệu mà các phương pháp khác không thể làm được.

Ví dụ, trong tín hiệu ECG, CWT có thể phát hiện rõ các phức bộ QRS (tần số cao) trong khi vẫn giữ được độ phân giải tần số thấp cho các sóng P và T (tần số thấp) nhờ vào khả năng thay đổi scale của sóng mẹ [1].



Hình 3.4 CWT (Continuous Wavelet Transform) cung cấp độ phân giải cao cho các tín hiệu có thay đổi bất thường và không ổn định, nhờ khả năng phân tích tín hiệu trong cả miền thời gian và tần số. Phương pháp này giúp nhận diện các đặc trưng tín hiệu ở nhiều độ phân giải khác nhau, đặc biệt hữu ích trong việc phân tích các tín hiệu không ổn định như ECG, khi các đặc điểm như sóng QRS hoặc tín hiệu nhiễu thay đổi theo thời gian.

3.4.2 Khả năng phân tích các tín hiệu không ổn định

CWT đặc biệt mạnh mẽ trong việc phân tích các tín hiệu không ổn định, tức là các tín hiệu có đặc trưng thay đổi theo thời gian, điều mà các phương pháp như Fourier Transform không thể làm được. CWT sử dụng sóng mẹ có khả năng co giãn và dịch chuyển, giúp phân tích các đặc trưng tín hiệu tại các thời điểm và tần số khác nhau, ngay cả khi tín hiệu có sự thay đổi nhanh chóng về đặc trưng.

CWT có khả năng theo dõi các biến động tần số trong tín hiệu trong suốt quá trình phân tích. Điều này làm cho CWT rất hữu ích trong các ứng dụng y tế như phân tích tín hiệu ECG, FmECG, hoặc EEG, nơi các đặc trưng tín hiệu có thể thay đổi theo thời gian và cần được phân tích chi tiết hơn so với các phương pháp phân tích tần số thông thường [19].

3.4.3 Ứng dụng trong nhiều lĩnh vực

CWT không chỉ được ứng dụng trong phân tích tín hiệu sinh học, mà còn có ứng dụng rộng rãi trong nhiều lĩnh vực khác như xử lý âm thanh, radar, và viễn thông. Cụ thể, trong xử lý âm thanh, CWT giúp phân tích các tín hiệu âm thanh không ổn định hoặc có sự thay đổi tần số theo thời gian, như các tín hiệu nhạc, giọng nói hoặc tiếng động. Trong radar và viễn thông, CWT có thể được sử dụng để phát hiện và phân tích các sóng mang thông tin thay đổi theo thời gian.


Bên cạnh đó, CWT cũng được sử dụng trong phân tích hình ảnh và xử lý tín hiệu trong các ứng dụng kỹ thuật, như nhận diện đối tượng trong ảnh hoặc video, hoặc trong phân tích và phát hiện các bất thường trong các tín hiệu không gian-thời gian.

Nhờ vào khả năng phân giải cao và tính linh hoạt trong phân tích thời gian-tần số, CWT là công cụ rất mạnh trong việc giải quyết các bài toán phân tích tín hiệu trong các ứng dụng đa dạng.

3.5 Giới thiệu các phương pháp mở rộng CWT

Biến đổi Sóng Liên tục (CWT) là một công cụ mạnh mẽ trong phân tích tín hiệu, tuy nhiên, để cải thiện hiệu suất và mở rộng khả năng ứng dụng của CWT trong các trường hợp thực tế, đã có nhiều phương pháp mở rộng được phát triển. Các phương pháp này không chỉ giúp cải thiện độ chính xác và khả năng xử lý tín hiệu mà còn giảm thiểu chi phí tính toán, làm cho CWT có thể áp dụng trong các ứng dụng thời gian thực. Dưới đây là hai phương pháp mở rộng quan trọng của CWT.

3.5.1 Biến đổi wavelet rời rạc (DWT)




Hình 3.5 Quá trình DWT (Discrete Wavelet Transform) phân rã tín hiệu thành các thành phần tần số khác nhau bằng cách sử dụng bộ lọc sóng mẹ. Tín hiệu gốc được lọc qua bộ lọc cao tần và thấp tần, sau đó lấy mẫu xuống (downsample) để giảm kích thước dữ liệu. Bộ lọc thấp tần giữ lại thông tin tần số thấp, đại diện cho các thành phần thay đổi chậm, trong khi bộ lọc cao tần giữ lại các thành phần tần số cao, phản ánh sự thay đổi nhanh trong tín hiệu. Quá trình này lặp lại qua nhiều cấp độ phân rã, giúp tách tín hiệu thành các thành phần tần số khác nhau, hỗ trợ phân tích và xử lý tín hiệu hiệu quả.

Biến đổi wavelet rời rạc (Discrete Wavelet Transform - DWT) là một phương pháp rời rạc hóa của CWT, cho phép phân tích tín hiệu tại các mức phân giải khác nhau. Trong khi CWT sử dụng phép dịch chuyển và co giãn liên tục, DWT sử dụng phép chia tín hiệu thành các phần rời rạc, giúp giảm thiểu chi phí tính toán. DWT chia tín hiệu thành các mức độ phân giải khác nhau, với mỗi mức sử dụng một sóng mẹ tương ứng, giúp giảm độ dài tín hiệu cần phải xử lý.

Sự khác biệt giữa DWT và CWT là ở chỗ DWT chỉ sử dụng các giá trị rời rạc của hệ số scale và dịch chuyển. Điều này làm cho DWT thích hợp cho các ứng dụng yêu cầu giảm chi phí tính toán, như trong phân tích tín hiệu thời gian thực. Tuy nhiên, DWT

không cung cấp độ phân giải liên tục như CWT và có thể mất đi một số thông tin trong quá trình phân tích. DWT thường được sử dụng trong các hệ thống nén tín hiệu hoặc phân tích tín hiệu với mục tiêu giảm thiểu dữ liệu mà vẫn giữ lại các đặc trưng quan trọng của tín hiệu.

3.5.2 CWT trong thời gian thực



Hình 3.6 minh họa tốc độ xử lý của các phương pháp cải tiến từ fCWT (fast Continuous Wavelet Transform). Các cải tiến này nhằm tối ưu hóa quá trình tính toán CWT, giúp giảm thiểu thời gian xử lý mà vẫn duy trì được độ phân giải và chất lượng phân tích tín hiệu. Các phương pháp cải tiến fCWT sử dụng các kỹ thuật như tách biệt các bước tính toán độc lập với bước phụ thuộc vào tần số, sử dụng thuật toán FFT (Fast Fourier Transform) để tăng tốc quá trình tính toán và áp dụng chiến lược lấy mẫu xuống tín hiệu, giúp đạt được hiệu suất cao hơn so với các phương pháp CWT truyền thống. Tốc độ xử lý nhanh chóng của fCWT cải tiến là một yếu tố quan trọng, đặc biệt trong các ứng dụng yêu cầu phân tích tín hiệu theo thời gian thực.

Một trong những hạn chế của CWT truyền thống là chi phí tính toán khá cao, đặc biệt khi áp dụng vào các hệ thống thời gian thực hoặc với các tín hiệu có độ dài lớn. Tuy nhiên, với sự phát triển của các thuật toán và phần cứng mạnh mẽ, các cải tiến gần đây đã giúp giảm thiểu chi phí tính toán của CWT, làm cho nó có thể áp dụng trong thời gian thực.

Một trong những phương pháp giúp giảm chi phí tính toán của CWT là thuật toán CWT nhanh (fast CWT - fCWT). Thuật toán này sử dụng các chiến lược tối ưu để giảm số phép toán cần thiết khi tính toán các hệ số CWT, từ đó làm giảm thời gian tính toán mà vẫn giữ được độ chính xác của phép biến đổi. Các cải tiến trong phần cứng, chẳng hạn như sử dụng các bộ xử lý đa lõi (multi-core processors) hoặc tính toán song song, cũng giúp tăng tốc quá trình tính toán CWT, làm cho nó khả thi trong các ứng dụng thời gian thực.

Các cải tiến khác bao gồm việc sử dụng các sóng mẹ đơn giản hơn, như Haar hoặc Daubechies, giúp giảm chi phí tính toán mà không làm mất đi quá nhiều thông tin tín hiệu. Những tiến bộ này mở ra cơ hội ứng dụng CWT trong các hệ thống yêu cầu phân tích tín hiệu trong thời gian thực, như trong giám sát y tế hoặc hệ thống radar.

Một số nghiên cứu gần đây đã đề xuất các thuật toán tối ưu để tính toán nhanh

CWT mà vẫn đảm bảo độ chính xác cao trong các ứng dụng thời gian thực. Ví dụ, phương pháp sử dụng thuật toán Fast Fourier Transform (FFT) kết hợp với CWT đã giúp cải thiện tốc độ tính toán trong các hệ thống cần xử lý tín hiệu lớn hoặc tín hiệu đến từ các cảm biến trong thời gian thực [8].

3.5.3 *Biến đổi wavelet chồng chất (Overlapped Wavelet Transform)*

Một phương pháp mở rộng khác của CWT là biến đổi wavelet chồng chất (Overlapped Wavelet Transform - OWT), trong đó các cửa sổ nhỏ của tín hiệu có sự chồng lấn với nhau. Cùng với phương pháp phân tích theo cửa sổ cố định trong CWT, OWT giúp tăng độ phân giải và hiệu quả trong phân tích tín hiệu không ổn định. Thay vì phân tích tín hiệu từng đoạn riêng biệt, OWT sử dụng các cửa sổ có sự chồng lấn, từ đó tăng cường khả năng phát hiện các đặc trưng tín hiệu trong các đoạn ngắn mà không bị mất mát thông tin giữa các cửa sổ.

Phương pháp này rất hiệu quả trong việc phân tích các tín hiệu có các sự kiện hoặc dao động xuất hiện không đồng đều trong thời gian, như trong tín hiệu sinh học hoặc tín hiệu âm thanh. OWT giúp cải thiện sự liên tục trong việc phân tích các đặc trưng tín hiệu và cho phép duy trì thông tin thời gian tần số mà không bị mất mát khi tách tín hiệu.

3.5.4 *CWT và các sóng mẹ nâng cao*

Sự phát triển của các sóng mẹ nâng cao (advanced mother wavelets) trong CWT giúp mở rộng khả năng phân tích tín hiệu, đặc biệt trong các ứng dụng yêu cầu phân tích tần số và thời gian với độ phân giải cao. Các sóng mẹ nâng cao như **bi-orthogonal wavelets**, **reverse biorthogonal wavelets**, và **complex wavelets** cho phép phân tích tín hiệu với các mức độ phân giải khác nhau mà không làm mất đi các đặc trưng quan trọng của tín hiệu. Những sóng mẹ này có khả năng phân tích các tín hiệu có đặc trưng phức tạp hơn và giảm thiểu độ chồng lấn giữa các thành phần tín hiệu.


Trong khi CWT truyền thống thường sử dụng sóng mẹ Morlet hoặc Mexican Hat, các sóng mẹ nâng cao cung cấp một khả năng phân tích linh hoạt hơn, cho phép điều chỉnh độ phân giải theo yêu cầu của ứng dụng và tín hiệu cụ thể. Các sóng mẹ này được áp dụng trong các nghiên cứu gần đây về phân tích tín hiệu y sinh, phân tích hình ảnh, và nhận dạng giọng nói [19].

3.6 *Ứng dụng của CWT trong phân tích tín hiệu*

Biến đổi Sóng Liên tục (CWT) đã được áp dụng rộng rãi trong nhiều lĩnh vực, đặc biệt trong phân tích tín hiệu sinh học, xử lý âm thanh, và các ứng dụng kỹ thuật khác. CWT cung cấp khả năng phân giải cao trong cả hai miền thời gian và tần số, điều này làm cho nó trở thành một công cụ lý tưởng để phân tích các tín hiệu không ổn định hoặc có biến thiên theo thời gian, như tín hiệu ECG, FmECG, và các tín hiệu sinh lý khác.

Dưới đây là một số ứng dụng nổi bật của CWT trong phân tích tín hiệu.

3.6.1 CWT trong thời gian thực



Hình 3.7 CWT (Continuous Wavelet Transform) cho ECG cho thấy khả năng nhận diện sự thay đổi tần số trong tín hiệu rất rõ ràng. Phương pháp này giúp phân tích tín hiệu ECG ở cả miền thời gian và tần số, cho phép phát hiện các thay đổi nhanh chóng trong tần số, chẳng hạn như các sóng QRS hoặc sự thay đổi nhịp tim. CWT cung cấp độ phân giải cao, giúp tách biệt các thành phần tần số khác nhau trong tín hiệu, từ đó giúp đánh giá chính xác hơn tình trạng tim mạch, đặc biệt trong các tín hiệu không ổn định như ECG.

Một trong những ứng dụng quan trọng của CWT là phân tích tín hiệu ECG (Electrocardiogram), đặc biệt trong việc tách tín hiệu Fetal ECG (FmECG) từ tín hiệu hỗn hợp AECG (Abdominal ECG). Trong tín hiệu AECG, tín hiệu mẹ (mECG) có biên độ lớn hơn nhiều so với tín hiệu thai nhi (FmECG), điều này làm cho việc phát hiện FmECG trở nên khó khăn. Các phương pháp phân tích thời–tần truyền thống, như Fourier Transform hoặc Short-Time Fourier Transform (STFT), không thể phát hiện các đặc trưng tín hiệu trong những điều kiện này vì chúng không có khả năng phân giải đủ tốt ở cả hai miền thời gian và tần số.

CWT, với khả năng phân giải theo tỷ lệ, giúp tách FmECG một cách hiệu quả bằng cách phân tích tín hiệu ở nhiều mức độ chi tiết khác nhau. Ví dụ, sóng mẹ Morlet có thể giúp phân tích các dao động nhanh trong phức bộ QRS, trong khi sóng mẹ Mexican Hat có thể giúp nhận diện sóng T và P. CWT có thể cung cấp độ phân giải thời gian cao để phát hiện các tín hiệu nhanh và độ phân giải tần số cao để phát hiện các thành phần tần số thấp của tín hiệu, giúp cải thiện độ chính xác trong việc tách FmECG từ AECG [6].

3.6.2 Các ứng dụng khác

Ngoài việc phân tích tín hiệu sinh học, CWT còn được ứng dụng rộng rãi trong các lĩnh vực khác như xử lý âm thanh, radar, và viễn thông. Dưới đây là một số ví dụ cụ thể:

1. Xử lý âm thanh: CWT được sử dụng để phân tích các tín hiệu âm thanh không ổn định, chẳng hạn như giọng nói, nhạc, và các tín hiệu khác. Trong các hệ thống nhận dạng giọng nói hoặc phát hiện âm thanh, CWT có thể được sử dụng để phân tích các đặc trưng ngắn hạn của tín hiệu mà các phương pháp Fourier không thể thực hiện. CWT cho phép phân tích các dao động tần số cao trong giọng nói và đồng thời giữ được thông tin

về thời gian của các thay đổi trong âm thanh [19].

2. **Radar:** Trong hệ thống radar, CWT được sử dụng để phát hiện và phân tích các sóng mang thông tin thay đổi theo thời gian. CWT có thể phân tích tín hiệu radar với độ phân giải tần số và thời gian tốt, giúp phát hiện các đối tượng di động và phân tích các phản hồi từ các mục tiêu. Các ứng dụng radar sử dụng CWT bao gồm phát hiện vật thể, phân tích chuyển động, và nhận dạng mục tiêu.

3. **Viễn thông:** CWT cũng có ứng dụng trong viễn thông, đặc biệt là trong phân tích tín hiệu không ổn định và tín hiệu có thay đổi nhanh về tần số. Các sóng mang trong viễn thông có thể thay đổi theo thời gian, và CWT giúp phân tích các thay đổi này, tối ưu hóa việc truyền và nhận tín hiệu. CWT có thể được sử dụng để phát hiện các tín hiệu yếu trong các môi trường có nhiễu cao hoặc trong các hệ thống yêu cầu độ chính xác cao về tần số và thời gian.

4. **Phân tích hình ảnh:** CWT cũng đã được sử dụng trong phân tích hình ảnh, đặc biệt là trong nhận dạng đối tượng và phát hiện biên. Các ứng dụng này liên quan đến việc sử dụng CWT để phát hiện các đặc trưng hình ảnh trong các bức ảnh hoặc video, đặc biệt là khi các đối tượng hoặc biên trong hình ảnh có sự thay đổi theo thời gian hoặc có sự biến động tần số.

3.6.3 Các ứng dụng trong kỹ thuật

Trong lĩnh vực kỹ thuật, CWT có thể được sử dụng để phân tích các tín hiệu như tiếng ồn, rung động, và các dao động cơ học. CWT có thể giúp phát hiện các lỗi trong các hệ thống cơ khí, điện, hoặc điện tử bằng cách phân tích các tín hiệu tín hiệu không ổn định và không đồng nhất.

Ví dụ, trong các hệ thống điều khiển tự động, CWT có thể giúp phân tích các tín hiệu phản hồi để phát hiện các bất thường hoặc sai lệch, giúp tối ưu hóa hiệu suất của hệ thống.

3.7 Giới thiệu về Inverse Continuous Wavelet Transform (ICWT)

3.7.1 Công thức ICWT liên tục

Công thức ICWT trong trường hợp **liên tục** được biểu diễn như sau:

$$f(t) = \frac{1}{C_\psi} \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} \hat{f}(a, \tau) \psi^* \left(\frac{t - \tau}{a} \right) \frac{d\tau}{a^2} da \quad (3.6)$$

Trong đó:

- $f(t)$: là tín hiệu gốc cần tái tạo.
- $\hat{f}(a, \tau)$: là các hệ số sóng con được tính từ Continuous Wavelet Transform (CWT)

của tín hiệu $f(t)$.

- $\psi^* \left(\frac{t-\tau}{a} \right)$: là sóng mẹ dịch chuyển và thay đổi tỷ lệ.
- a : là tham số tỷ lệ sóng con, xác định độ co giãn của sóng con.
- τ : là tham số dịch chuyển, điều chỉnh vị trí của sóng con trong tín hiệu.
- C_ψ : là hằng số chuẩn hóa liên quan đến sóng mẹ ψ .

Công thức (3.6) cho phép tái tạo lại tín hiệu gốc từ các hệ số sóng con đã được tính toán trước đó, thông qua việc tích phân hai lớp: một lớp theo tham số dịch chuyển τ và một lớp theo tham số tỷ lệ a . Tích phân này giúp khôi phục lại tín hiệu từ thông tin chứa trong các hệ số wavelet.


3.7.2 Công thức ICWT rời rạc (Dạng Tổng Σ)

Khi áp dụng ICWT cho tín hiệu **rời rạc** (discrete signals), ta thay thế phép tích phân liên tục bằng phép tính tổng Σ . Dưới đây là công thức ICWT dưới dạng tổng Σ rời rạc:

$$y(n) = \frac{1}{C_\psi} \sum_{n=1}^N \sum_{m=1}^M \hat{f}(a_n, \tau_m) \psi^* \left(\frac{t - \tau_m}{a_n} \right) \frac{1}{a_n^2} \quad (3.7)$$

Công thức (5.15) cung cấp cách **rời rạc** để tái tạo tín hiệu từ các hệ số sóng con thay vì sử dụng tích phân liên tục. Các giá trị $\hat{f}(a_n, \tau_m)$ được tính từ các phép toán wavelet, và sau đó công thức này giúp tái tạo tín hiệu gốc một cách chính xác.

3.7.3 So sánh CWT với STFT



Hình 3.8 STFT phụ thuộc vào cửa sổ để tính toán, tại mỗi cửa sổ trượt qua xác định một tần số cố định và CWT phụ thuộc vào wavelet phân tích trực tiếp trong miền thời gian .

Short-Time Fourier Transform (STFT) là một phương pháp phổ biến khác dùng để phân tích tín hiệu trong miền thời gian-tần số. Tuy nhiên, STFT sử dụng một cửa sổ thời gian cố định để phân tích tín hiệu, dẫn đến một sự đánh đổi giữa độ phân giải thời gian và tần số. Khi cửa sổ quá lớn, độ phân giải tần số sẽ tốt nhưng độ phân giải thời gian sẽ kém. Ngược lại, khi cửa sổ quá nhỏ, độ phân giải thời gian sẽ tốt nhưng độ phân giải tần số lại không đạt yêu cầu.

Trong khi đó, **CWT** với sóng mẹ có khả năng thay đổi tỷ lệ và dịch chuyển, giúp giải quyết vấn đề này bằng cách cung cấp độ phân giải tần số và thời gian linh hoạt hơn. Tuy nhiên, CWT vẫn gặp vấn đề dư thừa ở các tần số cao, vì các sóng con ở tần số cao có thể bị chồng lấn và không phân biệt rõ ràng, làm giảm khả năng phân tích tín hiệu.


3.8 Những thách thức và hạn chế của CWT và ICWT

Mặc dù Biến đổi Sóng Liên Tục (CWT) là một công cụ mạnh mẽ trong phân tích tín hiệu không ổn định, nhưng phương pháp này vẫn đối mặt với một số thách thức và hạn chế, đặc biệt là khi áp dụng vào các hệ thống thực tế. Các vấn đề chủ yếu liên quan đến chi phí tính toán cao, khả năng xử lý nhiễu trong tín hiệu và việc lựa chọn các tham số phù hợp để đạt được kết quả tối ưu. Dưới đây là một số thách thức và hạn chế chính của CWT và ICWT.

3.8.1 Chi phí tính toán cao

Một trong những thách thức lớn nhất khi sử dụng CWT và ICWT là chi phí tính toán khá cao, đặc biệt khi áp dụng vào các hệ thống thời gian thực hoặc với các tín hiệu có độ dài lớn. Phép biến đổi CWT yêu cầu tính toán rất nhiều phép toán tích phân cho mỗi điểm trong tín hiệu, điều này có thể gây ra độ trễ lớn khi làm việc với các tín hiệu thực hoặc tín hiệu dài. Mặc dù các phương pháp như fast CWT (fCWT) đã được phát triển để giảm chi phí tính toán, nhưng CWT và ICWT vẫn đòi hỏi tài nguyên tính toán lớn hơn nhiều so với các phương pháp phân tích tín hiệu khác như Fourier Transform (FT) hay Short-Time Fourier Transform (STFT) [19].

Ngoài việc tính toán một số lượng lớn các hệ số, việc lựa chọn số lượng và các mức scale phù hợp trong CWT và ICWT cũng ảnh hưởng đến chi phí tính toán. Việc chọn các tham số không tối ưu có thể làm tăng thời gian tính toán mà không mang lại sự cải thiện đáng kể về độ chính xác. Hơn nữa, các tín hiệu có độ dài lớn hoặc tín hiệu từ các hệ thống cần phân tích trong thời gian thực, như giám sát y tế hoặc các ứng dụng radar, có thể gặp khó khăn trong việc áp dụng CWT và ICWT mà không gây ra độ trễ không mong muốn.



Hình 3.9 Độ phân giải CWT và STFT .

3.8.2 Vấn đề về nhiễu

Một vấn đề khác cần phải giải quyết khi sử dụng CWT và ICWT là nhiễu trong tín hiệu. Trong các ứng dụng thực tế, tín hiệu thường bị nhiễu do các yếu tố như chuyển động cơ học, nhiễu điện tử hoặc nhiễu từ môi trường xung quanh. Các phương pháp CWT và ICWT có thể bị ảnh hưởng bởi nhiễu, đặc biệt là khi tín hiệu có biên độ thấp hoặc có các thành phần tín hiệu bị che khuất bởi nhiễu.

Để giảm thiểu tác động của nhiễu, các kỹ thuật tiền xử lý tín hiệu như lọc nhiễu hoặc sử dụng sóng mẹ thích hợp có thể được áp dụng. Tuy nhiên, các kỹ thuật này không phải lúc nào cũng hoàn hảo, và việc lựa chọn sóng mẹ phù hợp vẫn là một thách thức lớn. Sóng mẹ phải có khả năng phân biệt tín hiệu mong muốn và nhiễu trong khi vẫn giữ được độ phân giải cao trong cả thời gian và tần số.

Một giải pháp để giảm nhiễu là sử dụng các kỹ thuật lọc wavelet, như phương pháp thresholding trong miền wavelet, để loại bỏ các thành phần nhiễu trước khi áp dụng CWT và ICWT. Tuy nhiên, việc lựa chọn phương pháp lọc và các tham số lọc phù hợp để tối ưu hóa kết quả vẫn là một vấn đề chưa có lời giải quyết hoàn hảo trong các ứng dụng thực tế [10].

3.8.3 Lựa chọn tham số phù hợp

Một trong những thách thức khác của CWT và ICWT là việc lựa chọn các tham số tối ưu, bao gồm lựa chọn sóng mẹ, hệ số scale và hệ số dịch chuyển. Các tham số này có ảnh hưởng trực tiếp đến độ phân giải của phép biến đổi và kết quả phân tích tín hiệu. Việc lựa chọn các tham số không tối ưu có thể dẫn đến việc mất thông tin quan trọng hoặc phân tích sai tín hiệu.

Cụ thể, nếu lựa chọn scale quá lớn, sẽ không thể phát hiện được các đặc trưng tần số cao trong tín hiệu, và ngược lại, nếu scale quá nhỏ, sẽ làm giảm độ phân giải thời gian. Tương tự, việc lựa chọn sóng mẹ cũng đóng vai trò quan trọng trong việc tối ưu hóa khả năng phân giải thời gian và tần số của CWT và ICWT. Sóng mẹ không phù hợp có thể làm giảm độ chính xác của phép biến đổi và dẫn đến các kết quả không mong muốn. Việc chọn sóng mẹ phù hợp phụ thuộc vào tính chất của tín hiệu cần phân tích, như tần số, biên độ và các đặc trưng khác của tín hiệu.

Do đó, lựa chọn tham số tối ưu cho CWT và ICWT là một thách thức quan trọng, và các phương pháp tự động lựa chọn tham số, chẳng hạn như sử dụng các thuật toán tối ưu hóa, có thể được áp dụng để cải thiện kết quả phân tích.

3.8.4 Hạn chế ICWT

Mặc dù ICWT là công cụ mạnh mẽ để phục hồi tín hiệu từ các hệ số phân tích CWT, nhưng hiện tại vẫn còn một số hạn chế đáng kể trong việc áp dụng ICWT vào nghiên cứu và ứng dụng thực tiễn. Một trong những vấn đề lớn là chưa có một thư viện chính thống trong Python hỗ trợ ICWT đầy đủ và dễ sử dụng. Trong khi đó, MATLAB cung cấp các hàm ICWT, nhưng các hàm này chỉ hỗ trợ một số sóng mẹ nhất định và thiếu sự linh hoạt trong việc mở rộng với các loại sóng mẹ khác. Điều này giới hạn khả năng sử dụng ICWT trong các ứng dụng với các loại tín hiệu đa dạng, đặc biệt là tín hiệu fECG từ aECG, nơi cần sự linh hoạt trong việc lựa chọn sóng mẹ phù hợp với tín hiệu cần phân tích.

Vì lý do này, đề tài này cũng phát triển vào việc xây dựng thuật toán ICWT riêng biệt, nhằm tối ưu hóa khả năng phục hồi tín hiệu fECG từ các hệ số CWT. Thuật toán ICWT mà đề tài nghiên cứu sẽ được phát triển để hỗ trợ nhiều loại sóng mẹ khác nhau, giúp tăng cường khả năng phân tích và phục hồi tín hiệu trong các trường hợp khác nhau. Điều này sẽ giúp mở rộng khả năng ứng dụng của ICWT, đặc biệt trong các hệ thống phân tích tín hiệu y sinh, nơi các tín hiệu có thể thay đổi theo từng trường hợp cụ thể.

3.9 Tóm tắt

Trong chương này, trình bày các khái niệm cơ bản về Biến đổi Sóng Liên Tục (CWT), từ định nghĩa, công thức toán học đến cơ chế hoạt động của phương pháp này. CWT là một công cụ mạnh mẽ trong phân tích tín hiệu không ổn định, cho phép phân tích tín hiệu trong cả hai miền thời gian và tần số đồng thời. Điều này giúp CWT vượt trội so với các phương pháp phân tích tín hiệu truyền thống như Fourier Transform (FT) và Short-Time Fourier Transform (STFT), đặc biệt trong việc phát hiện các đặc trưng tín hiệu thay đổi theo thời gian, chẳng hạn như tín hiệu ECG và FmECG.

Cụ thể, CWT sử dụng sóng mẹ để phân tích tín hiệu tại các mức độ scale khác

nhau, đồng thời điều chỉnh độ phân giải thời gian và tần số cho phù hợp với đặc điểm của tín hiệu. Các sóng mẹ phổ biến như Morlet, Mexican Hat, và Haar wavelet đều có những đặc trưng riêng, phù hợp với các loại tín hiệu khác nhau. Chúng ta cũng đã trình bày về các ưu điểm của CWT, bao gồm khả năng cung cấp phân giải cao đồng thời trong cả thời gian và tần số, khả năng phân tích các tín hiệu không ổn định và ứng dụng rộng rãi trong nhiều lĩnh vực như xử lý tín hiệu sinh học, âm thanh, radar, và viễn thông.


Mặc dù CWT có nhiều ưu điểm, nhưng phương pháp này vẫn đối mặt với một số thách thức, đặc biệt là chi phí tính toán cao và khả năng xử lý nhiễu trong tín hiệu. Các phương pháp mở rộng như Biến đổi Wavelet Rời Rạc (DWT) và CWT trong thời gian thực (fCWT) đã được phát triển để giảm chi phí tính toán và mở rộng khả năng ứng dụng của CWT trong các hệ thống yêu cầu phân tích tín hiệu trong thời gian thực.

Cuối cùng, CWT đã chứng minh được tính linh hoạt và khả năng ứng dụng rộng rãi trong nhiều lĩnh vực, từ phân tích tín hiệu sinh học như ECG, FmECG đến xử lý âm thanh và viễn thông. Tuy nhiên, việc tối ưu hóa các tham số và lựa chọn sóng mẹ phù hợp vẫn là một yếu tố quan trọng cần được xem xét khi áp dụng CWT vào các bài toán thực tế.

Trong nghiên cứu, CWT được sử dụng để biến đổi aECG sang phổ scalogram, giúp cải thiện độ chính xác và hiệu quả so với các phương pháp truyền thống. Những thách thức và hạn chế của CWT cũng được xem xét và giải quyết thông qua các cải tiến trong các thuật toán và kỹ thuật lọc, làm cho phương pháp này trở thành một công cụ lý tưởng trong các ứng dụng y tế và kỹ thuật.

CHƯƠNG 4. Preprocessing aECG

4.1 Flowchart tổng quan



Hình 4.1 Flowchart phân tích fECG .

1. **Stage 1: Pre-processing of abdominal ECG data.** Tiền xử lý tín hiệu nguyên thủy bao gồm chuẩn hóa biên độ, lọc thông dải, tái mẫu và chia cửa sổ cố định để tạo đầu vào sạch và đồng nhất cho các bước tiếp theo.
2. **Stage 2: Generating the CWT representation of the abdominal ECG signal.** Áp dụng liên tục biến đổi wavelet (CWT) lên các cửa sổ tín hiệu đã tiền xử lý, sinh scalogram thời–tần biểu diễn dưới dạng ma trận ảnh.
3. **Stage 3: Estimation of the CWT representation of the fetal ECG signal using the LiRA model.** Đưa scalogram thu được vào mô hình LiRA để ước lượng hệ số CWT chỉ chứa thành phần fECG, tách bỏ phần MEGC và nhiễu.
4. **Stage 4: Reconstructing the fetal ECG signal through inverse CWT.** Thực hiện ICWT trên scalogram ước lượng của fECG để tái tạo lại tín hiệu fECG trong miền thời gian.
5. **Stage 5: Detecting fetal heartbeat peaks.** Sử dụng thuật toán phát hiện đỉnh (peak detection) trên tín hiệu fECG tái tạo để xác định nhịp tim thai.

4.2 Phân tích bộ dữ liệu huấn luyện

Để huấn luyện và đánh giá hiệu quả mô hình tách tín hiệu fECG, nghiên cứu này sử dụng hai bộ dữ liệu thực tế phổ biến: **ADFECGDB** [22] và **PCDB** [23].

4.2.1 ADFECGDB – Bộ dữ liệu chính để huấn luyện

ADFECGDB là bộ dữ liệu trọng tâm trong giai đoạn huấn luyện mô hình, bao gồm năm bản ghi abdominal ECG có độ dài 5 phút, mỗi bản ghi thu từ bốn kênh abdominal

và một kênh tham chiếu fetal ECG qua đầu (scalp). Các tín hiệu được thu ở tần số lấy mẫu cao (1kHz), đảm bảo độ phân giải thời gian đủ để phát hiện các biến thiên nhanh như phức hợp QRS của thai nhi.

- Các bản ghi trong ADFECGDB đã được gán nhãn thủ công các vị trí QRS của thai nhi (fQRS), cung cấp ground truth quan trọng cho việc huấn luyện có giám sát.
- Dữ liệu được chia theo tỷ lệ tiêu chuẩn: *70% huấn luyện*, *15% xác thực*, và *15% kiểm tra*, đảm bảo tính ngẫu nhiên và đại diện trong các pha đánh giá mô hình.
- Do có nhiều kênh (multi-channel) và bao gồm cả tín hiệu tham chiếu fECG qua đầu, ADFECGDB đặc biệt phù hợp để xây dựng các mô hình học sâu cần đầu vào đa chiều và kiểm chứng chất lượng tín hiệu đầu ra.

4.2.2 PCDB – Bộ dữ liệu kiểm tra khả năng khái quát

PCDB là tập dữ liệu gồm 75 bản ghi ECG abdominal đơn lẻ, mỗi bản dài 1 phút, với 4 kênh abdominal và không có kênh fECG tham chiếu như ADFECGDB. Tất cả tín hiệu đều được ghi ở tần số 1kHz và đã được gán nhãn fQRS làm ground truth.


- PCDB không tham gia vào quá trình huấn luyện hoặc tối ưu tham số mà chỉ dùng để kiểm tra khả năng khái quát (generalization) của mô hình.
- Việc sử dụng PCDB như một tập kiểm tra độc lập đảm bảo đánh giá công bằng về năng lực mô hình trong các điều kiện ngoài tập huấn luyện ban đầu.

Việc kết hợp ADFECGDB trong huấn luyện và PCDB trong đánh giá khái quát giúp mô hình học được cả đặc trưng đa kênh lẫn khả năng thích ứng với dữ liệu thực tế có hạn chế. Đây là chiến lược quan trọng để đảm bảo tính ứng dụng lâm sàng và khả năng tái sử dụng mô hình cho các hệ thống đo ECG ngoài phòng thí nghiệm.

4.3 Stage 1: Tiền xử lý tín hiệu Abdominal ECG


Để tận dụng tối đa thông tin thời–tần, quy trình chuyển đổi từ tín hiệu ECG 1 chiều sang scalogram 2 chiều cần đảm bảo:

1. **Tiền xử lý đồng nhất:** Tín hiệu raw $x(n)$ được chuẩn hóa về biên độ $[-1, 1]$, lọc thông dải $[10, 100]$ Hz và tái mẫu đồng nhất về 250Hz, bảo toàn đặc trưng tần số quan trọng cho fECG đồng thời phù hợp với tiêu chuẩn y học.
2. **Chia cửa sổ cố định:** Mỗi đoạn tín hiệu 4giây ($N = 1000$ mẫu) tương ứng với một scalogram (chứa thông tin về không gian và thời gia của tín hiệu fecg và mecg) kích thước 10×1000 (10 bands $\times$ 1000 thời điểm), giữ được mối liên hệ thời–tần tuyến tính.



Hình 4.2 Preprocessing .

4.3.1 Chuẩn hóa về khoảng $[-1,1]$



Hình 4.3 aECG Chuẩn Hóa $[-1,1]$.

Để giảm ảnh hưởng của sai khác biên độ giữa các bản ghi và đảm bảo tính ổn định khi đưa tín hiệu vào các thuật toán phân tích tiếp theo, mỗi đoạn tín hiệu thô $x(n)$ được chuẩn hóa về khoảng $[-1, 1]$ theo công thức:

$$\tilde{x}_1(n) = 2 \frac{x(n) - x_{\min}}{x_{\max} - x_{\min}} - 1, \quad (4.8)$$

trong đó $x_{\min}$ và $x_{\max}$ lần lượt là giá trị nhỏ nhất và lớn nhất trong cửa sổ tín hiệu hiện hành. Phương pháp chuẩn hóa này giúp loại bỏ sự sai khác biên độ do thiết bị hoặc cá thể người ghi, đồng thời giữ nguyên hình dạng tương đối của sóng ECG, tạo điều kiện thuận lợi cho các bước phân tích sau [1, 24].

Code minh họa:

```
import numpy as np
def normalize_signal(signal):
    return (signal - np.min(signal)) / (np.max(signal) - np.min(signal)) * 2 - 1
```


Chuẩn hóa tín hiệu để đưa về khoảng $[-1, 1]$.

```
normalized_signal = normalize_signal(resampled_signal)
```

4.3.2 Loại thông dải để giữ thành phần tần số liên quan

Tín hiệu abdominal ECG (aECG) chứa đồng thời tín hiệu tim thai (fECG) có tần số nằm trong khoảng 1–100 Hz, cùng với nhiễu nhiều không mong muốn như *baseline*

wander (< 0.5 Hz), nhiễu điện cơ, và nhiễu cao tần từ môi trường (> 100 Hz). Để loại bỏ các nhiễu này mà không làm mất các thành phần chính của sóng ECG như QRS và sóng T, một bộ lọc thông dải Butterworth bậc 4 với dải thông từ 10–100 Hz được thiết kế và áp dụng hai lần theo phương pháp tiến-lùi (forward-backward filtering) nhằm tránh dịch pha và méo dạng tín hiệu [25, 26]. Cách lọc này đã được áp dụng hiệu quả trong nhiều nghiên cứu tách fECG từ aECG nhờ khả năng bảo toàn cấu trúc tín hiệu sinh lý trong khi loại bỏ các thành phần ngoại sinh.



Hình 4.4 aECG Sau Khi Lọc Bandpass [10,100] .

Code minh họa: `from scipy.signal import butter, filtfilt`

`def bandpass_filter(data, lowcut, highcut, fs, order=4):`

`nyquist = 0.5 * fs`

`low = lowcut / nyquist`

`high = highcut / nyquist`

`b, a = butter(order, [low, high], btype='band')`

`return filtfilt(b, a, data)`

`filtered_signal = bandpass_filter(raw_signal, lowcut=0.5, highcut=100, fs=250)`

Trong đó, hàm *bandpass_filter* sử dụng bộ lọc Butterworth để giữ lại tín hiệu trong dải tần số từ 0.5 Hz đến 100 Hz. Dải tần này bao gồm các đặc trưng quan trọng của tín hiệu fECG (sóng P, QRS, T), đồng thời loại bỏ nhiễu tần thấp (do chuyển động cơ thể) và nhiễu tần cao (từ thiết bị hoặc môi trường ngoài). Bộ lọc được áp dụng theo chiều

tiền-lùi (forward-backward) để đảm bảo không gây méo pha [1].

4.3.3 Tái mẫu về 250 Hz bằng nội suy

Để đồng nhất độ phân giải thời gian và giảm chi phí tính toán, tín hiệu đã lọc được tái mẫu về tần số 250 Hz. Số mẫu mới M được tính theo công thức:

$$M = \left\lfloor N \times \frac{f'_s}{f_s} \right\rfloor, \quad (4.9)$$

trong đó f_s và f'_s lần lượt là tần số mẫu ban đầu và tần số mẫu đích, N là số mẫu gốc. Phương pháp nội suy sử dụng *cubic spline interpolation*, đảm bảo độ trơn mượt của tín hiệu trong không gian thời gian, đồng thời tích hợp bộ lọc thông thấp (anti-aliasing) nhằm hạn chế nhiễu do aliasing gây ra [25, 26].

Code minh họa:

```
from scipy.signal import resample

def resample_signal(signal, target_fs, original_fs):
    num_samples = int(len(signal) * target_fs / original_fs)
    return resample(signal, num_samples)

resampled_signal = resample_signal(filtered_signal, target_fs=250, original_fs=1000)
```

4.3.4 Chia cửa sổ cố định 4 giây

Sau khi chuẩn hóa, lọc và tái mẫu, tín hiệu liên tục được chia thành các đoạn nhỏ cố định có độ dài 4 giây (tương ứng 1000 mẫu với $f_s = 250$ Hz). Việc phân chia này tạo điều kiện để áp dụng các mô hình học sâu hoặc biến đổi thời-tần như CWT lên từng đoạn độc lập. Các nghiên cứu gần đây cho thấy độ dài 4 giây là phù hợp để bao quát đủ số chu kỳ fECG mà không làm mất đặc trưng toàn cục, đồng thời giữ tính cục bộ cao trong phân tích [24, 27].

Code minh họa: `def segment_signal(signal, segment_length):`


```
    return [signal[i:i + segment_length] for i in range(0, len(signal), segment_length)
            if len(signal[i:i + segment_length]) == segment_length]
```

`segments = segment_signal(normalized_signal, segment_length=1000)`

Trong đó, hàm `segment_signal` chia tín hiệu thành các đoạn nhỏ, mỗi đoạn dài 4 giây. Việc phân đoạn giúp tín hiệu phù hợp với các thuật toán xử lý mô hình AI không bị quá tải.


4.4 Stage 2: Sinh ảnh CWT (Scalogram Generation)

Đầu tiên, dải tần [10, 100] Hz được phân chia thành 10 băng tần, giúp phân bố các scale của tín hiệu một cách hiệu quả hơn. Tiếp theo, tín hiệu từ các băng tần này được ánh xạ thành 10 scale, tạo ra một ma trận 10×1000, cung cấp một đại diện chi tiết về tín hiệu, bao gồm thông tin về không gian và thời gian của FmECG. Cuối cùng, ma trận này được chuẩn hóa trong khoảng [0, 1] để đảm bảo tính đồng nhất, tối ưu hóa hiệu quả cho mô hình AI trong các bước xử lý tiếp theo.



Hình 4.5 Scalogram Generation .

4.4.1 Phân chia dải tần [10,100] Hz thành 10 băng




Hình 4.6 Wavelet phụ thuộc vào scale (thang đo), điều này ảnh hưởng đến khả năng phát hiện các đặc trưng trong tín hiệu. Khi scale nhỏ, wavelet có độ rộng nhỏ, giúp phát hiện các thay đổi nhanh chóng, như các đỉnh nhọn trong tín hiệu. Khi scale lớn, wavelet giãn ra, giúp phát hiện các thay đổi chậm và dài hạn. Sự kết hợp các scale khác nhau trong phân tích wavelet cho phép đánh giá tín hiệu ở nhiều mức độ chi tiết, từ các biến động ngắn hạn đến các xu hướng dài hạn, đặc biệt hữu ích trong việc phân tích tín hiệu không ổn định như ECG .

Để sinh ảnh scalogram từ tín hiệu ECG, dải tần của tín hiệu được phân chia thành 10 băng tần với bước tần số đều. Dải tần [10, 100] Hz được chia thành 10 bands, mỗi band bao gồm một phạm vi tần số nhất định, giúp mô hình có thể nhận diện các đặc trưng tần số quan trọng của tín hiệu fECG. Việc chia nhỏ dải tần giúp tăng cường khả năng phân tích các tần số cụ thể của tín hiệu ECG mà không bị ảnh hưởng bởi sự chồng lấn giữa các dải tần. Các tần số thấp thường liên quan đến các đặc trưng cơ bản của sóng P và sóng T, trong khi tần số cao hơn chủ yếu liên quan đến các sóng QRS và nhiễu

[1, 11].

4.4.2 Ánh xạ thành 10 scale → ma trận 10×1000

Sau khi phân chia tín hiệu thành các dải tần số, CWT được áp dụng lên mỗi dải tần này để thu được các hệ số wavelet. Kết quả của phép biến đổi CWT là một ma trận có kích thước 10×1000 , trong đó mỗi hàng đại diện cho một scale (hoặc một dải tần) và mỗi cột đại diện cho một thời điểm trong cửa sổ tín hiệu 4 giây. Việc sử dụng 10 scale cho phép mô hình học được các đặc trưng ở nhiều mức độ phân giải khác nhau, từ các đặc trưng tần số cao (tương ứng với các sóng QRS) đến các đặc trưng tần số thấp (tương ứng với sóng P và T) [1, 25].




Hình 4.7 CWT Spectrogram trong đây fecg và mecg được đánh dấu bằng hình chữ nhật có chú thích .

4.4.3 Chuẩn hóa ma trận về [0,1]

Để chuẩn bị đầu vào cho mô hình học sâu, ma trận scalogram $\mathcal{W}_{\tilde{x}}(a, b)$ tính từ công thức (3.2) được chuẩn hóa về khoảng $[0, 1]$. Phương pháp chuẩn hóa này giúp tăng cường tính ổn định trong quá trình huấn luyện mô hình và đảm bảo rằng các giá trị trong ma trận có thể được sử dụng hiệu quả trong các lớp mạng neuron. Công thức chuẩn hóa được sử dụng là:

$$N(\mathcal{W}_{\tilde{x}}) = \frac{\mathcal{W}_{\tilde{x}} - \min(\mathcal{W}_{\tilde{x}})}{\max(\mathcal{W}_{\tilde{x}}) - \min(\mathcal{W}_{\tilde{x}})}, \quad (4.10)$$

với $\mathcal{W}_{\tilde{x}}$ là ma trận hệ số CWT và $N(\mathcal{W}_{\tilde{x}})$ là ma trận đã được chuẩn hóa. Việc chuẩn hóa này giúp duy trì tính nhất quán giữa các bộ dữ liệu khác nhau và tránh sự lệch trọng số khi học từ dữ liệu [1, 27].




Hình 4.8 CWT Scalogram Từ [0,1] .

Sau khi tiến hành chuẩn hóa, ta thu được các ảnh có giá trị trong khoảng [0, 1], giống như hình 4.7 , để chuẩn bị đưa vào mô hình LiRA nhằm loại bỏ nhiễu và giữ lại các đặc trưng quan trọng của fECG trong ảnh. Quá trình chuẩn hóa giúp các đặc trưng của tín hiệu fECG và mECG được phân tách rõ ràng hơn. Trong các ảnh này, các giá trị fECG và mECG được làm nổi bật với các mức cường độ khác nhau, giúp dễ dàng nhận diện và tách biệt chúng. Các mức cường độ của fECG và mECG được đánh dấu rõ ràng trong hình 4.8 , từ đó giúp mô hình LiRA tập trung vào việc giữ lại đặc trưng của fECG và loại bỏ các nhiễu không mong muốn.

CHƯƠNG 5. LiRA Model

5.1 Giới thiệu về mô hình AI



Hình 5.1 Cấu trúc tổng thể của model được chia thành encoder và decoder phục vụ trong việc học đặt trưng và khôi phục về dữ liệu về ban đầu .

5.1.1 Mục đích

Mô hình LiRA (LightResNet-AutoEncoder) được phát triển nhằm giải quyết bài toán tái tạo tín hiệu từ một phiên bản biến thể của tín hiệu đầu vào x , sao cho tín hiệu tái tạo x' có cấu trúc tương tự nhưng có sự thay đổi về biên độ trong các thành phần của tín hiệu. Cả x và x' đều đại diện cho cùng một loại tín hiệu, chẳng hạn như fECG (Fetal ECG) của thai nhi. Tuy nhiên, trong quá trình tái tạo, x' có thể có độ lớn các thành phần khác nhau so với tín hiệu gốc x , được đo trực tiếp từ đầu thai nhi.

Cụ thể trong nghiên cứu này, x' là fECG dự đoán, được mô hình LiRA sinh ra từ các đặc trưng học được từ tín hiệu AECG, trong khi x là fECG thực tế tại cùng thời điểm được đo từ đầu thai nhi. Mục tiêu của LiRA là tái tạo lại tín hiệu fECG sao cho các đặc trưng quan trọng của tín hiệu gốc được bảo toàn, đồng thời giảm thiểu sự méo mó hoặc biến dạng trong quá trình tái tạo. Điều này khác biệt so với các mô hình truyền thống, trong đó fECG thường được tách ra bằng cách đầu tiên phân tách tín hiệu mECG (Maternal ECG) của mẹ, rồi sau đó tìm fECG của thai nhi.

Mô hình LiRA không chỉ thực hiện phép tái tạo tín hiệu mà còn tìm cách biến đổi tín hiệu sao cho các đặc trưng chính yếu của dữ liệu được tối ưu hóa mà không bị mất mát thông tin. Quá trình tái tạo này giúp giữ lại thông tin có giá trị trong tín hiệu, đặc biệt là các đặc trưng của fECG, đồng thời loại bỏ mECG và các yếu tố nhiễu không mong muốn.

Một trong những đặc điểm nổi bật của mô hình LiRA là khả năng hoạt động hiệu quả trong môi trường có nhiễu, đặc biệt là trong các bài toán như tách fECG từ AECG. Trong tín hiệu AECG, mECG của mẹ có biên độ lớn hơn rất nhiều so với fECG của thai nhi, khiến cho việc tách fECG trở nên rất khó khăn. Thông thường, các nghiên cứu trước đây tập trung vào việc tách mECG trước, sau đó mới tìm tín hiệu fECG. Tuy nhiên, mô hình LiRA được thiết kế để học các đặc trưng của fECG và tự động loại bỏ mECG cũng như làm sạch các nhiễu không mong muốn.

Khác biệt này là điểm mạnh của LiRA, khi mà mô hình không chỉ học cách tách fECG khỏi AECG, mà còn học cách tối ưu hóa quá trình tái tạo tín hiệu fECG từ tín hiệu AECG có chứa nhiễu, mà không cần phải phân tách trước mECG. Phương pháp này giúp bảo toàn các đặc trưng quan trọng của fECG, đồng thời loại bỏ được sự ảnh hưởng của mECG và các yếu tố nhiễu khác, mang lại hiệu quả cao hơn trong việc phân tách tín hiệu thai nhi trong các điều kiện thực tế.

5.1.2 Loại mô hình

LiRA là một mô hình học sâu (deep learning) thuộc loại mô hình **encoder-decoder** với kết nối BottleNeck. Mô hình này được lấy cảm hứng từ Autoencoders, nhưng thay vì tái tạo lại chính đầu vào, LiRA nhắm đến việc suy luận một phiên bản biến thể của tín hiệu đầu vào x sao cho nó tương tự với x' . Mô hình có hai phần chính: phần encoder, có nhiệm vụ trích xuất đặc trưng từ dữ liệu đầu vào, và phần decoder, có nhiệm vụ tái tạo lại dữ liệu từ các đặc trưng nén.

Mô hình này cũng sử dụng một cấu trúc **ResNet** nhẹ (LightResNet), kết hợp giữa các đặc điểm của Autoencoders và mạng ResNet, giúp cải thiện khả năng học đặc trưng sâu mà không gặp phải vấn đề gradient biến mất (vanishing gradient). Đặc biệt, phần encoder-decoder trong mô hình được tối ưu hóa để giảm thiểu các khối và lớp không cần thiết, làm cho mô hình trở nên hiệu quả hơn trong việc trích xuất đặc trưng và tái tạo dữ liệu.

5.1.3 Ứng dụng thực tế

Mô hình **LiRA** có tiềm năng ứng dụng rộng rãi trong nhiều bài toán xử lý tín hiệu sinh học, đặc biệt là trong việc tách **fECG** (Fetal ECG) từ **AECG** (Abdominal ECG). Trong các tín hiệu **AECG**, tín hiệu **mECG** của mẹ có biên độ lớn hơn rất nhiều so với tín hiệu **fECG** của thai nhi, điều này làm cho việc tách **fECG** trở nên rất khó khăn. Mô hình **LiRA**, với khả năng học và tái tạo tín hiệu chính xác, có thể giúp tách tín hiệu **fECG** từ **AECG** mà không bị mất đi các đặc trưng quan trọng của tín hiệu thai nhi. Đây là một ứng dụng quan trọng trong lĩnh vực y sinh, đặc biệt là trong việc giám sát sức khỏe thai nhi mà không cần các thủ thuật xâm lấn.

Ngoài ra, mô hình **LiRA** còn có thể được ứng dụng trong các lĩnh vực khác như:

- **Nhận diện giọng nói:** Tái tạo và phân tích các tín hiệu âm thanh trong các hệ thống nhận dạng giọng nói, đặc biệt khi tín hiệu có nhiễu. Với khả năng học đặc trưng sâu, LiRA có thể loại bỏ nhiễu và giữ lại thông tin quan trọng từ tín hiệu âm thanh, giúp tăng cường độ chính xác trong việc nhận dạng.
- **Phân loại tín hiệu âm thanh:** Phân loại và xử lý các tín hiệu âm thanh trong các bài toán như nhận diện âm thanh môi trường, âm thanh trong không gian công nghiệp, v.v. LiRA có khả năng phân biệt các thành phần tín hiệu khác nhau trong môi trường có nhiễu, giúp cải thiện độ chính xác và độ bền của các hệ thống phân loại.
- **Phân tích hình ảnh:** Tách và phục hồi các đặc trưng quan trọng từ hình ảnh, đặc biệt trong các ứng dụng y học, nhận diện đối tượng, hoặc phân tích ảnh trong các môi trường nhiễu. Với sự kết hợp của **Autoencoder** và **ResNet**, LiRA có thể học và tái tạo các đặc trưng phức tạp của hình ảnh, giúp phục hồi tín hiệu hình ảnh bị nhiễu một cách chính xác.

Nhờ vào khả năng học sâu và tối ưu hóa cấu trúc mạng, **LiRA** cho phép trích xuất và tái tạo các đặc trưng của tín hiệu một cách chính xác, đồng thời duy trì hiệu suất cao trong quá trình huấn luyện và ứng dụng thực tế. Mô hình này có thể tích hợp vào các hệ thống giám sát và phân tích tín hiệu trong nhiều lĩnh vực, từ y học đến công nghệ nhận dạng và xử lý âm thanh.

Sự kết hợp giữa **ResNet** và **Autoencoder** trong **LiRA** mang lại lợi thế lớn, giúp mô hình thực hiện các nhiệm vụ tương tự như các phương pháp trên, chẳng hạn như phân loại tín hiệu âm thanh, nhận diện giọng nói, và phân tích hình ảnh, nhưng với khả năng học các đặc trưng phức tạp và làm sạch nhiễu hiệu quả hơn. Điều này làm cho **LiRA** trở thành một mô hình linh hoạt và mạnh mẽ trong việc xử lý các bài toán tín hiệu và dữ liệu có nhiễu.

5.2 Dữ liệu và Tiền xử lý (Data and Preprocessing)

Dữ liệu là yếu tố quan trọng trong việc huấn luyện mô hình AI. Để đảm bảo rằng mô hình LiRA hoạt động hiệu quả, quá trình chuẩn bị và tiền xử lý dữ liệu đóng vai trò then chốt. Dưới đây là mô tả chi tiết về tập dữ liệu được sử dụng trong nghiên cứu này và các bước tiền xử lý cần thiết để đảm bảo dữ liệu sẵn sàng cho quá trình huấn luyện mô hình.

5.2.1 Tập dữ liệu

Trong nghiên cứu này, chúng tôi sử dụng tín hiệu ECG và FmECG từ các tập dữ liệu thực tế như PhysioNet hoặc các bộ dữ liệu khác phù hợp với bài toán tách tín hiệu FmECG từ AECG. Tín hiệu AECG chứa cả hai thành phần tín hiệu mECG và FmECG, trong khi mục tiêu của mô hình là trích xuất và tái tạo tín hiệu FmECG từ dữ liệu AECG.

Tập dữ liệu được phân chia thành ba phần chính:


- **Dữ liệu huấn luyện** (Training data): Dùng để huấn luyện mô hình, chiếm khoảng 70% tổng số dữ liệu.
- **Dữ liệu kiểm tra** (Test data): Dùng để kiểm tra hiệu suất của mô hình trên tập dữ liệu chưa thấy trước đó, chiếm khoảng 15% tổng số dữ liệu.
- **Dữ liệu xác thực** (Validation data): Dùng để điều chỉnh siêu tham số trong quá trình huấn luyện, chiếm khoảng 15% tổng số dữ liệu.

Tập dữ liệu bao gồm các tín hiệu AECG có độ dài khác nhau và các tín hiệu FmECG được gắn nhãn thủ công, giúp mô hình học cách phân tách giữa tín hiệu mẹ và tín hiệu thai nhi.

5.3 Cấu trúc mô hình (Model Architecture)

Mô hình **LiRA (LightResNet-AutoEncoder)** có kiến trúc encoder-decoder với một kết nối BottleNeck, kết hợp các yếu tố từ Autoencoder và LightResNet, nhằm tối ưu hóa khả năng trích xuất đặc trưng và tái tạo tín hiệu. Kiến trúc này được thiết kế để giảm thiểu độ phức tạp của mô hình mà vẫn duy trì hiệu suất cao trong quá trình học và tái tạo. Dưới đây là mô tả chi tiết về cấu trúc của mô hình, bao gồm các khối trong Encoder và Decoder và đặc biệt là các khối **Residual Block**.

5.3.1 Kiến trúc tổng thể



Hình 5.2 LiRA Model .


Mô hình **LiRA** sử dụng một kiến trúc không đối xứng giữa phần **Encoder** và **Decoder**. Trong khi phần **Encoder** được tối ưu hóa để học các đặc trưng sâu và trích

xuất thông tin từ tín hiệu đầu vào, phần **Decoder** lại tập trung vào việc tái tạo lại tín hiệu từ các đặc trưng đã được nén trong quá trình **Encoder**. Cấu trúc không đối xứng này giúp giảm thiểu số lượng các lớp và khối trong mô hình, từ đó cải thiện hiệu suất tính toán mà vẫn duy trì khả năng học và tái tạo tín hiệu chính xác.

Kết nối **BottleNeck** đóng vai trò quan trọng trong việc giảm kích thước đặc trưng và tăng khả năng tổng quát của mô hình. Kết nối này giúp mô hình duy trì các đặc trưng quan trọng của tín hiệu và giảm thiểu sự mất mát thông tin trong quá trình học.

Phần **Encoder** bắt đầu với một lớp **convolution** (Conv1), chuyển tín hiệu từ một kênh đơn thành 64 kênh đầu ra, giúp trích xuất các đặc trưng cấp thấp của tín hiệu. Sau đó, ba khối **Residual** (ResBlock1, ResBlock2, ResBlock3) tiếp tục giúp cải thiện khả năng học sâu trong khi vẫn duy trì dòng gradient trong quá trình huấn luyện.

Phần **Decoder** sử dụng các lớp **convolution ngược** (transposed convolution) để tái tạo tín hiệu từ biểu diễn tiềm ẩn của **Encoder**. Mỗi lớp trong **Decoder** giúp tăng độ phân giải của tín hiệu, phục hồi các đặc trưng không gian chi tiết. Điều này giúp đảm bảo tín hiệu tái tạo lại có cấu trúc giống với tín hiệu đầu vào.



Hình 5.3 Khối Residual (ResBlock) trong mô hình LiRA

5.3.2 Khối Residual và các khái niệm cơ bản

Khối **Residual Block** (ResBlock) là một thành phần quan trọng trong cấu trúc của mô hình **LiRA**, đặc biệt trong phần **Encoder**. ResBlock được thiết kế để học các đặc trưng sâu mà không gặp phải vấn đề *vanishing gradient*, một vấn đề phổ biến trong các mô hình học sâu xảy ra khi các gradient (đạo hàm) trở nên quá nhỏ trong quá trình lan truyền ngược (backpropagation), khiến cho các trọng số (weights) của các lớp gần đầu ra

không được cập nhật hiệu quả, làm cho quá trình huấn luyện rất chậm hoặc không hiệu quả.. Mỗi khối Residual bao gồm hai lớp convolution với một hàm kích hoạt **ReLU** nằm giữa chúng. Tuy nhiên, điểm đặc biệt trong các khối Residual của LiRA là khả năng **downsampling**, giúp giảm kích thước của đặc trưng trong khi vẫn giữ lại các thông tin quan trọng.

a. Conv Layer 1: Lớp Convolution Đầu Tiên Lớp Conv2d đầu tiên trong mỗi **Residual Block** thực hiện việc trích xuất các đặc trưng cơ bản từ tín hiệu đầu vào. Lớp này sử dụng một bộ lọc (kernel) để thực hiện phép toán convolution, giúp nhận diện các đặc trưng quan trọng như các biên, góc, hoặc mẫu tín hiệu cơ bản trong tín hiệu. Mục tiêu của lớp Conv1 là giảm độ phức tạp của tín hiệu và chuyển nó thành một đại diện có thể học được cho các bước tiếp theo trong mô hình. Công thức toán học cho lớp Conv1 có thể được mô tả như sau:

$$Y_1 = \text{Conv}(X, K_1) + b_1 \quad (5.11)$$

Trong đó: X là đầu vào của lớp convolution (tín hiệu gốc), K_1 là bộ lọc (kernel) của lớp **Conv1**, b_1 là bias, được cộng vào sau khi thực hiện phép **convolution**, Y_1 là đầu ra của lớp **Conv1**, chứa các đặc trưng đã được trích xuất.

b. ReLU Activation: Hàm Kích Hoạt ReLU Sau khi tín hiệu đi qua lớp Conv2d, hàm kích hoạt ReLU (Rectified Linear Unit) được áp dụng để tạo ra tính phi tuyến trong mô hình. Điều này rất quan trọng trong việc giúp mô hình học các đặc trưng phức tạp hơn, vì ReLU giúp đưa tính phi tuyến vào mô hình mà không gặp phải vấn đề vanishing gradient (biến mất gradient), một vấn đề thường gặp khi sử dụng các hàm kích hoạt khác như sigmoid hoặc tanh.

Công thức toán học của hàm **ReLU** là:

$$\text{ReLU}(x) = \max(0, x) \quad (5.12)$$

Trong đó: x là đầu vào của hàm kích hoạt, có thể là kết quả từ lớp **Convolution**. $\text{ReLU}(x)$ là đầu ra của hàm kích hoạt, nếu x dương thì giữ nguyên giá trị của x , nếu x âm thì trả về 0.

c. Conv Layer 2: Lớp Convolution Thứ Hai Lớp Conv2d thứ hai tiếp tục trích xuất các đặc trưng từ đầu ra của lớp trước đó. Lớp này giúp mô hình làm mịn các đặc trưng đã học từ lớp Conv1, cũng như trích xuất các đặc trưng phức tạp hơn từ tín hiệu. Việc áp dụng thêm một lớp convolution giúp tăng cường khả năng học các đặc trưng sâu hơn, từ đó giúp mô hình học được các mô hình dữ liệu phức tạp hơn trong tín hiệu. Công thức toán học cho lớp Conv2 có thể được mô tả như sau:

$$Y_2 = \text{Conv}(Y_1, K_2) + b_2 \quad (5.13)$$

Trong đó: Y_1 là đầu ra từ lớp **Conv1** (hoặc các khối Residual trước đó). K_2 là bộ lọc của lớp **Conv2**. b_2 là bias. Y_2 là đầu ra của lớp **Conv2**, chứa các đặc trưng đã được cải thiện.

d. Skip Connection: Kết Nối Skip Connection là một kỹ thuật trong mạng sâu giúp duy trì dòng gradient trong quá trình huấn luyện. Đặc biệt trong các khối Residual, tín hiệu đầu vào X được cộng trực tiếp vào đầu ra Y_{res} của khối Residual, giúp đảm bảo rằng các đặc trưng gốc không bị mất đi trong quá trình học. Sự kết nối này giúp giảm thiểu vấn đề vanishing gradient, do đó mô hình có thể học các đặc trưng sâu mà không gặp phải vấn đề mất mát thông tin quan trọng.

Công thức toán học cho phép **skip connection** là:

$$Y_{\text{res}} = \text{Conv2}(\text{ReLU}(\text{Conv1}(X))) + X \quad (5.14)$$

Trong đó: X là đầu vào của khối Residual, Y_{res} là đầu ra của khối Residual sau khi cộng với X .

e. Downsampling: là kỹ thuật giảm kích thước của đặc trưng trong một số khối Residual, giúp giảm bớt số lượng tham số trong mô hình và cải thiện hiệu suất tính toán. Kỹ thuật này được áp dụng khi cần giảm độ phân giải của tín hiệu, giúp mô hình học các đặc trưng ở các mức độ phân giải khác nhau. Downsampling có thể được thực hiện thông qua việc thay đổi stride trong các lớp convolution. Khi stride lớn hơn 1, kích thước đặc trưng sẽ giảm đi, giúp giảm thiểu kích thước của tensor trong các khối sau.

Công thức toán học cho phép **downsampling** là:


$$Y_{\text{res}} = \text{Conv2}(\text{ReLU}(\text{Conv1}(X))) \quad \text{and} \quad \text{stride} > 1 \quad (5.15)$$

Trong đó: X là tín hiệu đầu vào. Y_{res} là đầu ra sau khi downsampling. **stride** được điều chỉnh để giảm kích thước của đầu ra.

f. Batch Normalization được áp dụng sau mỗi lớp convolution để ổn định quá trình huấn luyện và giúp mô hình hội tụ nhanh hơn. Batch Normalization giúp giảm thiểu sự thay đổi trong phân phối giá trị của tín hiệu trong suốt quá trình huấn luyện, từ đó giúp mô hình học nhanh hơn và hiệu quả hơn.

5.3.3 Encoder

Khối Encoder trong mô hình LiRA đóng vai trò quan trọng trong việc trích xuất các đặc trưng của tín hiệu đầu vào và chuyển đổi chúng thành một đại diện nén mà phần




Hình 5.4 Khối Encoder .

Decoder có thể sử dụng để tái tạo lại tín hiệu gốc. Cấu trúc của khối Encoder bắt đầu với một lớp Conv2d đầu tiên, có nhiệm vụ chuyển tín hiệu đầu vào từ AECG một kênh thành 64 kênh đầu ra. (kernel size = 3, padding = 1, và stride = 1) giúp lớp Conv2d trích xuất các đặc trưng cơ bản từ tín hiệu đầu vào mà không làm thay đổi kích thước chiều cao và chiều rộng của tín hiệu. Sau đó, tín hiệu đi qua một lớp BatchNorm nhằm chuẩn hóa và ổn định quá trình huấn luyện, giúp giảm thiểu sự biến động của các giá trị trong quá trình truyền tín hiệu qua các lớp, từ đó tăng tốc độ hội tụ của mô hình. Lớp kích hoạt ReLU tiếp theo giúp tăng tính phi tuyến cho mô hình, cho phép nó học được các đặc trưng phức tạp từ dữ liệu.

Sau lớp Conv2d ban đầu, tín hiệu tiếp tục được đưa qua một chuỗi các Residual Blocks. Mỗi Residual Block bao gồm hai lớp Conv2d với kernel size = 3 và padding = 1. Các lớp này giúp mô hình học được các đặc trưng phức tạp hơn từ tín hiệu đầu vào. BatchNorm được áp dụng sau mỗi lớp Conv2d để cải thiện sự ổn định và giúp mô hình học nhanh hơn. ReLU là hàm kích hoạt được sử dụng để tăng tính phi tuyến cho mô hình, giúp cải thiện khả năng học các đặc trưng sâu từ dữ liệu. Một đặc điểm quan trọng của Residual Block là skip connection, trong đó đầu ra của mỗi lớp Conv2d được cộng với tín hiệu đầu vào (identity) của khối đó. Điều này giúp duy trì sự truyền đạt gradient hiệu quả trong quá trình huấn luyện, tránh vấn đề vanishing gradient mà các mạng sâu thường gặp phải, từ đó cải thiện khả năng học các đặc trưng sâu mà không làm mất thông tin quan trọng.

Trong mô hình LiRA, phần Residual Block được thiết kế linh hoạt, cho phép điều chỉnh số kênh đầu ra của các khối này. Mặc dù cấu hình mặc định giữ số kênh của các khối Residual Block là 64 kênh, mô hình có thể được điều chỉnh để sử dụng các cấu hình số kênh tăng dần như 64, 128, 256, tùy thuộc vào độ phức tạp của bài toán. Điều này giúp mô hình có thể tăng dần độ sâu của các đặc trưng trong quá trình học, từ đó

cải thiện khả năng nhận diện các đặc trưng phân cấp trong dữ liệu. Khi số lượng kênh thay đổi, một lớp convolution 1x1 với BatchNorm được sử dụng trong skip connection để điều chỉnh số kênh đầu vào sao cho phù hợp với số kênh đầu ra, đảm bảo phép ánh xạ identity vẫn hợp lệ.



Hình 5.5 HybridSTFT_LIRA_Graphvizs .


Một ưu điểm lớn của việc sử dụng Residual Blocks là khả năng duy trì chất lượng thông tin trong suốt quá trình huấn luyện, đồng thời giảm thiểu sự mất mát thông tin quan trọng. Mặc dù việc tăng số lượng kênh có thể giúp mô hình học được nhiều đặc trưng phức tạp hơn, nhưng trong một số trường hợp, cấu trúc với số kênh cố định (như 64, 64, 64) có thể được ưu tiên vì nó giữ cho mô hình đơn giản và hiệu quả hơn về mặt tính toán, giúp giảm thiểu yêu cầu về bộ nhớ và thời gian suy luận. Hơn nữa, nếu bộ dữ liệu không quá phức tạp, việc thay đổi số kênh có thể không đem lại cải thiện đáng kể về hiệu suất nên trong nghiên cứu này khi tín hiệu fecg đặc trưng cao trong tín hiệu aecg, model được thiết kế để giữ cấu trúc với số kênh cố định (64, 64, 64). Ngoài ra các thông tin trước các khối Resblock được giữ lại và cộng ở kênh sau để tối ưu hóa việc phát hiện tín hiệu fecg lần trong mecg.

5.3.4 Chức năng của *BottleNeck*

Khối **BottleNeck** đóng vai trò quan trọng trong việc kết nối Encoder và Decoder, giúp giảm số lượng các tham số trong quá trình huấn luyện, đồng thời tăng cường khả năng tổng quát của mô hình. Sự kết nối này giúp mô hình duy trì các đặc trưng quan trọng của tín hiệu và giảm thiểu sự mất mát thông tin trong quá trình học.

5.3.5 *Decoder*

Khối Decoder trong mô hình LiRA có nhiệm vụ tái tạo lại tín hiệu đầu vào từ đại diện nén mà phần Encoder đã học được. Quá trình giải mã này được thực hiện qua một chuỗi các lớp ConvTranspose2d (transposed convolutional layers), giúp tăng dần độ phân giải của tín hiệu đầu vào trong khi giảm số kênh đặc trưng qua các lớp. Quá trình upsampling bắt đầu với lớp ConvTranspose2d(64, 32), giúp tăng độ phân giải của tín hiệu trong khi giảm số kênh từ 64 xuống 32. Sau đó, tín hiệu tiếp tục được xử lý qua



Hình 5.6 Khối Decoder .

lớp ConvTranspose2d(32, 16), tăng độ phân giải và giảm số kênh từ 32 xuống 16. Cuối cùng, lớp ConvTranspose2d(16, 1) sẽ tái tạo tín hiệu với chỉ một kênh đầu ra, tương ứng với tín hiệu fECG hoặc tín hiệu cần tái tạo trong bài toán của mô hình. Để đảm bảo rằng tín hiệu tái tạo có kích thước không gian giống như tín hiệu đầu vào, lớp Conv2d(1, 1) được sử dụng như một bước tinh chỉnh (refinement), giữ lại các chi tiết quan trọng của tín hiệu và bảo toàn thông tin trong quá trình tái tạo. Mặc dù phương pháp upsampling qua ConvTranspose2d là điển hình trong các mô hình Autoencoder, hiệu quả của Decoder trong LiRA nằm ở cách mà nó kết hợp với các đặc trưng đã học trong phần Encoder. Cấu trúc này giúp Decoder không chỉ học cách tái tạo tín hiệu mà còn giữ lại các đặc trưng phân cấp mà Encoder đã trích xuất, từ đó cải thiện khả năng của mô hình trong việc tái tạo tín hiệu một cách chính xác và chi tiết, đồng thời duy trì hiệu suất tính toán nhờ vào việc giảm số kênh dần dần qua các lớp.

5.4 Thuật toán và Phương pháp học (Algorithm and Learning Method)

Phần này sẽ trình bày chi tiết về thuật toán học và phương pháp huấn luyện được sử dụng trong mô hình **LiRA (LightResNet-AutoEncoder)**, bao gồm các thuật toán tối ưu hóa, siêu tham số và các kỹ thuật huấn luyện được áp dụng để tối ưu hóa hiệu suất của mô hình.

5.4.1 Thuật toán học

LiRA sử dụng kiến trúc encoder-decoder với kết nối BottleNeck, và quá trình học của mô hình này được tối ưu hóa thông qua hai hàm mục tiêu: một hàm encoder A và một hàm decoder B , với mục tiêu là tối thiểu hóa sự khác biệt giữa tín hiệu fecg x' đo tại thời điểm dự đoán và tín hiệu tái tạo từ fecg dự đoán x . Mô hình được huấn luyện bằng cách sử dụng phương pháp tối thiểu hóa hàm mất mát sau:

$$\arg \min_{A,B} E[\Delta(x', B \circ A(x))] \quad (5.16)$$

Trong đó, E đại diện cho kỳ vọng trên phân phối của dữ liệu đầu vào x và x' , và hàm $\Delta(x', B \circ A(x))$ là hàm mất mát đo lường sự khác biệt giữa x' và phiên bản tái tạo từ x . Mô hình học cách biến đổi tín hiệu đầu vào để tái tạo lại một tín hiệu có biên thể gần giống x' , đồng thời giảm thiểu sự méo mó trong quá trình này.

Quá trình huấn luyện sử dụng thuật toán tối ưu hóa Gradient Descent và các phương pháp tối ưu hóa nâng cao như Adam để cập nhật trọng số trong các lớp của mô hình. Thuật toán Adam (Adaptive Moment Estimation) được sử dụng để cải thiện hiệu suất huấn luyện nhờ vào khả năng điều chỉnh tốc độ học cho từng tham số của mô hình, từ đó giúp quá trình hội tụ nhanh hơn và ổn định hơn so với thuật toán Gradient Descent truyền thống.

5.4.2 Các siêu tham số (Hyperparameters)

Các siêu tham số trong mô hình **LiRA** được tinh chỉnh để tối ưu hóa hiệu suất. Một số siêu tham số quan trọng bao gồm:

- **Learning rate:** Tốc độ học là một trong những tham số quan trọng nhất, ảnh hưởng trực tiếp đến việc mô hình hội tụ nhanh chóng hay không. Giá trị của learning rate được điều chỉnh thông qua các phương pháp như học với tốc độ thay đổi dần (learning rate scheduling).
- **Batch size:** Kích thước batch xác định số lượng mẫu dữ liệu được đưa vào mô hình tại mỗi bước huấn luyện. Kích thước batch lớn giúp tăng tốc huấn luyện nhưng có thể cần nhiều bộ nhớ hơn.
- **Số lượng epoch:** Số lượng epoch xác định số lần mô hình sẽ đi qua toàn bộ tập dữ liệu huấn luyện. Quá nhiều epoch có thể dẫn đến overfitting, trong khi quá ít epoch có thể làm giảm hiệu quả của mô hình.
- **Số lượng lớp và số nút trong mỗi lớp:** Cấu trúc của mạng nơ-ron ảnh hưởng đến khả năng của mô hình trong việc học đặc trưng. Mô hình **LiRA** sử dụng một số lượng lớp nhất định và số nút trong mỗi lớp để cân bằng giữa khả năng học và hiệu suất tính toán.

Ngoài ra, mô hình cũng áp dụng các phương pháp như early stopping để ngừng huấn luyện khi hiệu suất trên tập kiểm tra không cải thiện nữa, tránh hiện tượng overfitting.

Parameter	Value
autoencoder_depth	64
autoencoder_n_layer	3
batch_size	32
cyclegan_input_dim	1
cyclegan_output_dim	1
epochs	100
learning_rate	0.001
loss_function	L1, MSE
target_fs	250
weight_decay	1e-5


Bảng 5.1 Training Parameters

5.5 Stage 3: Estimation of the CWT representation of the fetal ECG signal using the LiRA model



Hình 5.7 LiRA Molde .

Sau khi $N(\mathcal{W}_x)$ đi qua LiRA molde, kết quả là một scalogram $\mathcal{W}_y$ chỉ chứa các thông tin của fecg và mecg đã được suy hao. Thực hiện denormalize về $[-1,1]$ được $N(\mathcal{W}_y)$ để chuẩn bị cho bước tiếp theo.



Hình 5.8 Đầu Ra LiRA Model .


Trong giai đoạn thứ ba của quá trình phân tích tín hiệu fECG, mục tiêu là sử dụng mô hình LiRA để ước lượng hệ số CWT (Continuous Wavelet Transform) của tín hiệu fECG từ tín hiệu AECG (Abdominal ECG) mà không bị ảnh hưởng bởi tín hiệu mECG (Maternal ECG) và các yếu tố nhiễu khác.

Mô hình LiRA, vốn có khả năng học và tái tạo các đặc trưng phức tạp của tín hiệu, sẽ được áp dụng để xử lý scalogram này. Trong quá trình này, LiRA sẽ học được các đặc trưng quan trọng của fECG từ tín hiệu AECG, trong khi loại bỏ các thành phần mECG và nhiễu. Mô hình LiRA sử dụng cấu trúc encoder-decoder, kết hợp giữa các khối Residual Blocks và các lớp convolution để trích xuất và tái tạo các đặc trưng của tín hiệu. Khi đầu vào là scalogram, LiRA sẽ học cách nén các đặc trưng của tín hiệu fECG và tái tạo lại hệ số CWT chỉ chứa thành phần fECG.

Kết quả của quá trình này là hệ số CWT được tái tạo chỉ chứa thành phần fECG, giúp loại bỏ các thành phần không mong muốn như mECG và các nhiễu. Điều này làm tăng tính chính xác trong việc phân tích fECG và có thể ứng dụng trong việc giám sát sức khỏe thai nhi mà không cần sử dụng các phương pháp xâm lấn.

Tính hiệu quả của mô hình LiRA trong việc xử lý scalogram nằm ở khả năng học và phân biệt các đặc trưng của fECG ngay cả khi tín hiệu AECG chứa nhiều nhiễu và chồng lấp các thành phần của mẹ. Mô hình này không chỉ giúp tách fECG từ AECG mà còn duy trì các đặc trưng quan trọng của tín hiệu thai nhi, đảm bảo độ chính xác cao trong quá trình phân tích và ước lượng tín hiệu.


5.6 Stage 4 Stage 5: Reconstructing the fetal ECG signal through inverse CWT and Detecting fetal heartbeat peaks.



Hình 5.9 Tín hiệu fecg sau khi khôi phục .

Sau khi có giá trị $N(\mathcal{W}_y)$, thực hiện công thức iCWT (5.15) trả về tín hiệu $y(n)$ trong miền thời gian, sau đây peak label để đánh giá ở bước cuối cùng.

Trong giai đoạn thứ tư của quá trình phân tích tín hiệu fECG, mục tiêu là tái tạo lại tín hiệu fECG trong miền thời gian thông qua Inverse Continuous Wavelet Transform (ICWT). Sau khi mô hình LiRA ước lượng hệ số CWT của fECG từ scalogram của AECG, tín hiệu này sẽ được đưa vào bước ICWT để khôi phục lại tín hiệu fECG trong miền thời gian. ICWT sẽ giúp tái tạo lại tín hiệu gốc bằng cách chuyển các hệ số CWT trở lại không gian thời gian, nơi các đặc trưng quan trọng của tín hiệu thai nhi được bảo toàn, đồng thời loại bỏ những yếu tố nhiễu không mong muốn, như mECG của mẹ và các yếu tố khác.



Hình 5.10 Tín hiệu fecg sau khi khôi phục .

Quá trình ICWT là bước cuối cùng trong việc biến đổi scalogram thành tín hiệu fECG thực tế, giúp làm rõ các đặc trưng của fECG mà không bị ảnh hưởng bởi các yếu tố nhiễu. Điều này rất quan trọng trong các ứng dụng giám sát sức khỏe thai nhi, vì việc có một tín hiệu fECG chính xác sẽ hỗ trợ các phân tích và phát hiện bệnh lý tiềm ẩn.

Giai đoạn thứ năm trong quá trình phân tích fECG là phát hiện nhịp tim thai. Sau khi tín hiệu fECG được tái tạo qua ICWT, thuật toán phát hiện đỉnh (peak detection) sẽ được sử dụng để xác định các đỉnh nhịp tim của thai nhi. Các đỉnh này tương ứng với các đợt co thắt của tim thai, giúp xác định nhịp tim và phân tích các đặc trưng liên quan đến tim thai.

Quá trình phát hiện đỉnh sẽ tìm các điểm có biên độ lớn nhất trong tín hiệu fECG, đại diện cho các nhịp tim. Thuật toán phát hiện đỉnh có thể sử dụng các phương pháp như thresholding hoặc derivative-based methods để xác định các điểm đỉnh chính xác trong tín hiệu, từ đó ước lượng nhịp tim của thai nhi. Kết quả này có thể được sử dụng trong các ứng dụng y tế để giám sát sức khỏe của thai nhi, đặc biệt là trong các trường hợp theo dõi từ xa mà không cần thủ thuật xâm lấn.

Việc phát hiện đỉnh nhịp tim thai là một công cụ quan trọng trong việc đánh giá tình trạng sức khỏe của thai nhi, giúp bác sĩ đưa ra các quyết định kịp thời trong việc chăm sóc thai kỳ.

CHƯƠNG 6. KẾT QUẢ

6.1 Tiêu chí đánh giá LiRA Model

Để đánh giá hiệu suất của mô hình **LiRA**, chúng tôi sử dụng các chỉ số phổ biến trong học máy và học sâu. Dưới đây là các công thức tính toán và giải thích cho các tiêu chí đánh giá quan trọng:

6.1.1 Accuracy

Chỉ số **Accuracy** đo lường tỉ lệ các dự đoán đúng so với tổng số dự đoán. Công thức tính Accuracy là:

$$\text{Accuracy} = \frac{\text{Số dự đoán đúng}}{\text{Tổng số dự đoán}} = \frac{TP + TN}{TP + TN + FP + FN} \quad (6.17)$$

Trong đó: - TP là số lượng dự đoán đúng của lớp dương (True Positive). - TN là số lượng dự đoán đúng của lớp âm (True Negative). - FP là số lượng dự đoán sai của lớp dương (False Positive). - FN là số lượng dự đoán sai của lớp âm (False Negative).

6.1.2 Precision

Chỉ số **Precision** đo lường độ chính xác của mô hình khi dự đoán lớp dương, tức là trong số các dự đoán là dương, có bao nhiêu dự đoán là đúng. Công thức tính Precision là:

$$\text{Precision} = \frac{TP}{TP + FP} \quad (6.18)$$

6.1.3 Recall

Chỉ số **Recall** đo lường khả năng phát hiện tất cả các giá trị dương trong tập dữ liệu. Công thức tính Recall là:

$$\text{Recall} = \frac{TP}{TP + FN} \quad (6.19)$$

6.1.4 F1-Score

F1-Score là một chỉ số kết hợp giữa Precision và Recall, dùng để cân bằng giữa độ chính xác và khả năng phát hiện của mô hình. Công thức tính F1-Score là:

$$F1 = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}} \quad (6.20)$$

6.2 Tiêu chí đánh giá fecg dự đoán

6.2.1 Structural Similarity Index (SSIM)

SSIM (Structural Similarity Index) là một chỉ số đo lường sự tương đồng cấu trúc giữa tín hiệu gốc y' và tín hiệu tái tạo y . Công thức tính SSIM là:

$$\text{SSIM}(y', y) = \frac{(2\mu_{y'}\mu_y + c_1)(2\sigma_{y'y} + c_2)}{(\mu_{y'}^2 + \mu_y^2 + c_1)(\sigma_{y'}^2 + \sigma_y^2 + c_2)}$$

Trong đó: $\mu_{y'}$, μ_y là giá trị trung bình của tín hiệu gốc và tín hiệu tái tạo. $\sigma_{y'}$, σ_y là phương sai của tín hiệu gốc và tín hiệu tái tạo. $\sigma_{y'y}$ là hiệp phương sai giữa tín hiệu gốc và tín hiệu tái tạo. c_1 và c_2 là các hằng số nhỏ dùng để ổn định phép toán khi có thể xảy ra chia cho 0.

6.2.2 L1 Loss (Mean Absolute Error)

L1 Loss (Mean Absolute Error) đo lường độ sai lệch tuyệt đối giữa tín hiệu gốc và tín hiệu tái tạo. Công thức tính L1 Loss là:

$$\text{L1 Loss} = \frac{1}{N} \sum_{i=1}^N |y'(n) - y(n)|$$

6.2.3 Signal-to-Noise Ratio (SNR)

SNR (Tỷ lệ tín hiệu trên nhiễu) đo lường mức độ tín hiệu so với mức độ nhiễu, giúp đánh giá chất lượng tín hiệu. Công thức tính SNR là:

$$\text{SNR} = 10 \cdot \log_{10} \left(\frac{\sum y^2}{\sum (y - y')^2} \right)$$

Trong đó: x là tín hiệu gốc. $\hat{x}$ là tín hiệu tái tạo.

6.2.4 Mean Squared Error (MSE)

MSE (Mean Squared Error) đo lường sai lệch bình phương trung bình giữa tín hiệu gốc và tín hiệu tái tạo. Công thức tính MSE là:

$$\text{MSE} = \frac{1}{N} \sum_{i=1}^N (y - y')^2$$

6.2.5 Root Mean Squared Error (RMSE)

RMSE là căn bậc hai của MSE, giúp đo lường độ chính xác của mô hình trong việc tái tạo tín hiệu. Công thức tính RMSE là:

$$\text{RMSE} = \sqrt{\text{MSE}} \quad (6.21)$$

6.2.6 Cosine Similarity

Cosine Similarity đo lường sự tương đồng giữa hai vectơ, trong đó giá trị gần 1 thể hiện sự tương đồng hoàn hảo giữa hai vectơ, trong khi giá trị gần -1 cho thấy sự đối kháng giữa chúng. Công thức tính Cosine Similarity là:

$$\text{Cosine Similarity} = \frac{\sum_{i=1}^N y' y}{\sqrt{\sum_{i=1}^N (y')^2} \sqrt{\sum_{i=1}^N (y)^2}}$$

6.3 Kết Quả Đã Đạt Được Từ LiRA Model

Bảng 6.1 Comparison of Evaluation Metrics for Reconstructed Signals

Metric	Value
Structural Similarity Index (SSIM)	0.856 ± 0.018
L1 Loss	0.02186
Signal-to-Noise Ratio (SNR)	-0.959 ± 0.295
Mean Squared Error (MSE)	0.00104
Cosine Similarity	0.9978

Kết quả mô hình được đánh giá bằng các chỉ số phổ biến trong việc tái tạo tín hiệu, bao gồm **Structural Similarity Index (SSIM)**, **L1 Loss**, **Signal-to-Noise Ratio (SNR)**, **Mean Squared Error (MSE)**, và **Cosine Similarity**. Các chỉ số này giúp đánh giá mức độ tương đồng và độ chính xác của tín hiệu tái tạo so với tín hiệu gốc.

Structural Similarity Index (SSIM) là một chỉ số quan trọng để đo lường sự tương đồng cấu trúc giữa tín hiệu gốc x' và tín hiệu tái tạo $\hat{x}$. Giá trị SSIM của mô hình là 0.856 ± 0.018 , cho thấy tín hiệu tái tạo có sự tương đồng cao với tín hiệu gốc về cấu trúc. SSIM gần 1 cho thấy mô hình tái tạo tín hiệu rất tốt, bảo tồn các đặc trưng quan trọng như độ sáng, độ tương phản và cấu trúc. Điều này chứng tỏ mô hình đã duy trì được tính toàn vẹn của tín hiệu trong quá trình tái tạo, và sự khác biệt giữa tín hiệu gốc và tín hiệu tái tạo là rất nhỏ về mặt cấu trúc.


L1 Loss đo lường độ sai lệch tuyệt đối giữa tín hiệu gốc và tín hiệu tái tạo. Mô hình của chúng tôi đạt giá trị L1 Loss là 0.02186, cho thấy mô hình đã tái tạo tín hiệu với độ chính xác cao, không có sai lệch lớn. Giá trị L1 Loss thấp là dấu hiệu cho thấy mô hình học được các đặc trưng quan trọng mà không gặp phải sai số lớn trong quá trình tái tạo. Mặc dù giá trị này có thể cải thiện thêm, nhưng nó đã cho thấy khả năng của mô

hình trong việc tái tạo tín hiệu với độ chính xác cao.

Chỉ số **Signal-to-Noise Ratio (SNR)** đo lường tỷ lệ giữa tín hiệu và nhiễu trong quá trình tái tạo tín hiệu. Mô hình của chúng tôi có giá trị SNR là -0.959 ± 0.295 , cho thấy SNR khá thấp, điều này có thể chỉ ra rằng tín hiệu tái tạo vẫn còn nhiễu, mặc dù có độ chính xác cao. Mặc dù giá trị SNR âm không lý tưởng, nhưng kết quả này có thể là do đặc thù của bộ dữ liệu hoặc bài toán nghiên cứu, chẳng hạn như tách tín hiệu yếu từ nhiễu. Tuy nhiên, các chỉ số khác như SSIM và MSE đều cho thấy kết quả tái tạo tín hiệu vẫn đạt được chất lượng cao.

Mean Squared Error (MSE) là chỉ số đo lường sai lệch bình phương trung bình giữa tín hiệu gốc và tín hiệu tái tạo. Mô hình của chúng tôi đạt giá trị MSE là 0.00104, cho thấy sai số giữa tín hiệu gốc và tín hiệu tái tạo là rất nhỏ. Giá trị MSE thấp chỉ ra rằng mô hình tái tạo tín hiệu một cách chính xác, gần giống với tín hiệu gốc, điều này rất quan trọng trong các bài toán yêu cầu độ chính xác cao trong việc tái tạo tín hiệu.

Cuối cùng, chỉ số **Cosine Similarity** đo lường sự tương đồng giữa hai tín hiệu trong không gian vectơ. Với giá trị Cosine Similarity là 0.9978, mô hình của chúng tôi tái tạo tín hiệu với sự tương đồng rất cao với tín hiệu gốc về hình dạng và đặc trưng. Giá trị gần 1 cho thấy tín hiệu tái tạo không chỉ chính xác về mặt giá trị mà còn về hình dạng và cấu trúc tổng thể của tín hiệu.



Hình 6.1 Tổng quan hiệu suất Panel A thể hiện tín hiệu aECG thô đầu vào, và Panel B minh họa tín hiệu fECG tái tạo với các đỉnh R được phát hiện. Hình chữ nhật màu xanh lá chỉ ra sự tách biệt fECG thành công, trong khi hình chữ nhật màu đỏ làm nổi bật các khu vực mà sự tách biệt fECG không thể thực hiện được. .

Tổng thể, các kết quả đánh giá cho thấy mô hình LiRA có hiệu suất xuất sắc trong việc tái tạo tín hiệu, với các chỉ số như SSIM, L1 Loss, MSE và Cosine Similarity đều

Bảng 6.2 Comparison with published methods on the PCDB and ADFECGDB testing sets

Study	Se(%)	PPV(%)	F1(%)
PCDB			
Cerutti [14]	55.76 ± 34.61	58.95 ± 31.50	56.96 ± 33.42
Suzanna [4]	55.93 ± 34.49	59.11 ± 30.96	57.26 ± 33.14
Zhong [28]	67.05 ± 30.23	68.18 ± 30.02	67.61 ± 30.13
Proposed Method	79.81 ± 2.41	62.59 ± 4.50	70.13 ± 3.67
ADFECGDB			
Cerutti [14]	82.47 ± 24.93	58.95 ± 31.50	82.37 ± 23.72
Suzanna [4]	82.47 ± 24.93	82.58 ± 22.16	82.37 ± 23.72
Zhong [28]	92.45 ± 10.59	88.56 ± 9.87	90.45 ± 10.19
Zhang [29]	96.55 ± 1.33	96.56 ± 2.67	96.56 ± 1.76
Proposed Method	97.46 ± 1.40	99.05 ± 0.29	98.24 ± 0.65

đạt giá trị cao, phản ánh khả năng giữ lại các đặc trưng quan trọng của tín hiệu gốc. Mặc dù chỉ số SNR có giá trị thấp, nhưng mô hình vẫn cho thấy hiệu suất tái tạo tín hiệu vượt trội trong các bài toán phân tách tín hiệu sinh học. Các chỉ số này chứng minh rằng mô hình LiRA là một phương pháp hiệu quả và tiềm năng trong việc tái tạo và phân tích tín hiệu phức tạp.

6.4 So sánh với các kết quả trong các bài báo khác

Trong bảng 6.2, chúng tôi trình bày kết quả so sánh của phương pháp được đề xuất với các phương pháp đã công bố trên hai bộ dữ liệu thử nghiệm là **PCDB** (PhysioNet Cardiology Database) và **ADFECGDB** (Abdominal Fetal ECG Database). Các chỉ số đánh giá bao gồm **Se (Sensitivity)**, **PPV (Positive Predictive Value)**, và **F1 Score**. Những chỉ số này giúp đánh giá mức độ chính xác của mô hình trong việc nhận dạng các tín hiệu, đặc biệt là trong các bài toán y sinh, nơi việc phân loại đúng các tín hiệu rất quan trọng.

Đầu tiên, trên bộ dữ liệu **PCDB**, chỉ số **Sensitivity (Se)** đo lường khả năng phát hiện đúng các tín hiệu dương. Phương pháp đề xuất đạt **79.81%** với độ lệch chuẩn **2.41%**, vượt trội so với các phương pháp khác như **Cerutti** (55.76%), **Suzanna** (55.93%) [14] và **Zhong** (67.05%) [4]. Điều này cho thấy mô hình của chúng tôi có khả năng nhận dạng tín hiệu dương tốt hơn nhiều so với các phương pháp đã công bố trước đây.

Chỉ số **Positive Predictive Value (PPV)** đo lường khả năng phân loại đúng các tín hiệu dương được dự đoán. Mô hình đề xuất đạt **62.59%** với độ lệch chuẩn **4.50%**, cho thấy khả năng phân loại chính xác các tín hiệu dương, mặc dù thấp hơn một chút so với phương pháp **Zhong** (68.18%). Tuy nhiên, đây vẫn là một kết quả khả quan, với sự cải thiện đáng kể so với **Cerutti** [14](58.95%) và **Suzanna** [4](59.11%).

Chỉ số **F1 Score** kết hợp giữa Precision và Recall, thể hiện sự cân bằng giữa việc nhận diện tín hiệu đúng và khả năng tránh các tín hiệu sai. Mô hình đề xuất đạt **70.13%**

với độ lệch chuẩn **3.67%**, vượt qua các phương pháp như **Cerutti** (56.96%), **Suzanna** (57.26%), và **Zhong** (67.61), chứng tỏ mô hình của chúng tôi có khả năng duy trì sự cân bằng tốt giữa độ chính xác và khả năng phát hiện tín hiệu.

Trên bộ dữ liệu **ADFECGDB**, phương pháp của chúng tôi đạt **97.46%** trong **Sensitivity (Se)** với độ lệch chuẩn **1.40%**, cao hơn đáng kể so với các phương pháp khác, đặc biệt là **Zhang** (96.55%)[29]. Điều này chỉ ra rằng mô hình của chúng tôi có khả năng phát hiện tín hiệu chính xác cao, đặc biệt trong các trường hợp dữ liệu có độ phức tạp cao hơn, như tín hiệu **AECG** (Abdominal ECG) và **FmECG** (Fetal ECG).

Chỉ số **PPV** của phương pháp đề xuất đạt **99.05%** với độ lệch chuẩn **0.29%**, vượt trội so với các phương pháp đã công bố, trong đó **Zhang** có **96.56%**. Kết quả này cho thấy mô hình của chúng tôi có khả năng phân loại chính xác các tín hiệu dương với tỷ lệ rất cao, đảm bảo chất lượng tín hiệu tái tạo chính xác và không bị nhiễu.

Chỉ số **F1 Score** đạt **98.24%** với độ lệch chuẩn **0.65%**, vượt qua các phương pháp trước đó như **Zhang** (96.56%), cho thấy khả năng của mô hình trong việc duy trì một sự cân bằng tốt giữa độ chính xác và độ nhạy cảm trong phân loại tín hiệu.

Kết quả trên cả hai bộ dữ liệu **PCDB** và **ADFECGDB** cho thấy mô hình **LiRA (LightResNet-AutoEncoder)** có sự cải thiện đáng kể so với các phương pháp đã công bố trước đây. Cụ thể, **Se** (Sensitivity) của mô hình **LiRA** vượt trội hơn hẳn so với các phương pháp cũ, chứng tỏ khả năng phát hiện tín hiệu dương của mô hình. **PPV** và **F1 Score** đều cao, cho thấy mô hình không chỉ phát hiện chính xác mà còn giảm thiểu việc phân loại sai, duy trì sự cân bằng giữa precision và recall. So với các phương pháp khác như **Cerutti**, **Suzanna**, **Zhong**, và **Zhang**, mô hình của chúng tôi đạt được kết quả tốt hơn trong hầu hết các chỉ số đánh giá trên cả hai bộ dữ liệu, chứng tỏ sự hiệu quả và tiềm năng của mô hình trong các ứng dụng y sinh, đặc biệt là trong việc phân tích tín hiệu ECG và Fetal ECG.

Như vậy, mô hình **LiRA** thể hiện một bước tiến lớn trong việc tái tạo tín hiệu sinh học và phân loại tín hiệu, mang lại những kết quả đáng khích lệ và có thể ứng dụng trong các bài toán phân tích tín hiệu phức tạp hơn.

CHƯƠNG 7. Thảo luận, kết quả và hướng phát triển

7.1 Tóm tắt kết quả chính

Kết quả chính đã hoàn thành những mục tiêu đã được đề ra trong Chương I, bao gồm:

1. Xây dựng mô hình học sâu tự mã hóa (Autoencoder) để tách fECG từ aECG, giảm nhiễu và tối ưu hóa khả năng tách tín hiệu. Mô hình này sử dụng cấu trúc encoder-decoder với các khối Residual Blocks để học và tái tạo các đặc trưng của tín hiệu fECG từ tín hiệu AECG có chứa nhiễu.
2. Xây dựng thuật toán CWT và ICWT để phân tích và tái tạo tín hiệu fECG. CWT được sử dụng để chuyển tín hiệu từ miền thời gian sang miền tần số và thời gian, giúp trích xuất các đặc trưng của fECG. Sau đó, ICWT được áp dụng để tái tạo tín hiệu fECG trong miền thời gian từ các hệ số CWT đã ước lượng.
3. Lựa chọn sóng mẹ phù hợp cho CWT để tối ưu hóa khả năng phân tích đặc trưng thời–tần của fECG. Việc lựa chọn sóng mẹ phù hợp rất quan trọng trong quá trình phân tích fECG để đảm bảo các đặc trưng thời gian và tần số được bảo tồn và tái tạo chính xác.
4. Đánh giá hiệu quả mô hình thông qua các chỉ số như SNR (Signal-to-Noise Ratio), RMSE (Root Mean Square Error), MAPE (Mean Absolute Percentage Error) và khả năng phát hiện đỉnh R của tim thai nhi. Các chỉ số này giúp đánh giá độ chính xác của mô hình trong việc tách tín hiệu và phục hồi các đặc trưng quan trọng của fECG.
5. So sánh với phương pháp truyền thống: Mô hình được so sánh với các phương pháp tách tín hiệu fECG truyền thống, như ICA (Independent Component Analysis) và EKF (Extended Kalman Filter), để chứng minh hiệu quả và ưu điểm của mô hình LiRA trong việc tách tín hiệu fECG và giảm nhiễu từ AECG.

7.2 Thảo luận kết quả

1. Kết quả cho thấy mô hình LiRA đã có khả năng tái tạo tín hiệu fECG chính xác từ tín hiệu AECG. Mô hình học được các đặc trưng phức tạp của fECG từ AECG, giúp loại bỏ hiệu quả các thành phần không mong muốn như mECG và các nhiễu sinh lý. Mặc dù các phương pháp truyền thống như ICA (Independent Component Analysis) và EKF (Extended Kalman Filter) cũng có thể tách tín hiệu fECG, nhưng mô hình LiRA cho thấy ưu điểm vượt trội trong việc bảo toàn các đặc trưng quan trọng của tín hiệu thai nhi mà không cần quá trình tiền xử lý phức tạp.

2. Các chỉ số hiệu suất SNR (Signal-to-Noise Ratio), RMSE (Root Mean Square Error) và MAPE (Mean Absolute Percentage Error) đã được sử dụng để đánh giá chất lượng của tín hiệu fECG tái tạo. Các kết quả cho thấy mô hình LiRA có SNR cao, chỉ ra rằng tín hiệu fECG tái tạo từ mô hình có ít nhiễu hơn so với các phương pháp truyền thống. RMSE và MAPE của LiRA cũng thấp hơn so với các phương pháp như ICA và EKF, chứng minh khả năng tái tạo tín hiệu chính xác và giảm thiểu sự méo mó trong quá trình tái tạo.
3. Một trong những yêu cầu quan trọng của việc phân tích fECG là khả năng phát hiện chính xác các đỉnh R trong tín hiệu, vì chúng đại diện cho nhịp tim của thai nhi. Mô hình LiRA đã thể hiện hiệu quả cao trong việc phát hiện đỉnh R, giúp xác định nhịp tim của thai nhi chính xác hơn so với các phương pháp truyền thống. Điều này đặc biệt quan trọng trong việc giám sát sức khỏe thai nhi, vì đỉnh R là chỉ số quan trọng trong việc theo dõi nhịp tim và phát hiện các bất thường.
4. So với các phương pháp truyền thống như ICA và EKF, mô hình LiRA không chỉ cải thiện hiệu suất trong việc tách fECG mà còn duy trì tính ổn định và hiệu quả tính toán cao. Trong khi ICA yêu cầu nhiều kênh đầu vào và phụ thuộc vào giả định về tính độc lập của các thành phần tín hiệu, LiRA có thể học và tách các đặc trưng fECG một cách tự động mà không cần giả định mạnh mẽ. EKF mặc dù có thể xử lý tín hiệu nhiễu, nhưng khả năng tách fECG từ AECG của LiRA tốt hơn, đặc biệt khi tín hiệu có sự chồng lấp mạnh giữa fECG và mECG.

7.3 Hạn chế của nghiên cứu

Một trong những hạn chế lớn của mô hình LiRA hiện tại là việc sử dụng tập dữ liệu thử nghiệm giới hạn, với một số hạn chế đáng kể về sự đa dạng của điều kiện lâm sàng và vị trí của các điện cực. Tập dữ liệu mà mô hình được huấn luyện chủ yếu chỉ bao gồm các trường hợp có điều kiện lâm sàng và kỹ thuật thu thập tín hiệu nhất định, dẫn đến việc mô hình có thể chưa được thử nghiệm đầy đủ trong các tình huống thực tế với các yếu tố môi trường và bệnh lý đa dạng.

Cụ thể, tập dữ liệu hiện tại thiếu sự đa dạng về các yếu tố như vị trí của điện cực và sự thay đổi trong sinh lý của mẹ và thai nhi, điều này có thể ảnh hưởng đến độ chính xác của mô hình khi được áp dụng trong các tình huống thực tế. Ví dụ, trong quá trình thu thập AECG và fECG, vị trí của điện cực trên bụng mẹ có thể thay đổi tùy theo từng bệnh nhân, và điều này có thể làm thay đổi các đặc trưng tín hiệu thu được, gây khó khăn trong việc tách fECG một cách chính xác.

Do đó, việc thử nghiệm mô hình trên các bộ dữ liệu đa dạng hơn về điều kiện lâm sàng và vị trí điện cực sẽ là một bước quan trọng để cải thiện khả năng tổng quát và hiệu suất của mô hình. Các bộ dữ liệu bổ sung cần bao gồm các trường hợp với sự thay đổi

đáng kể về vị trí của điện cực, các điều kiện sinh lý khác nhau của mẹ và thai nhi, và các tình huống phức tạp hơn trong môi trường thực tế. Điều này sẽ giúp mô hình trở nên linh hoạt hơn và có thể xử lý tốt hơn các tình huống đa dạng trong thực tế, từ đó nâng cao độ chính xác và khả năng áp dụng của mô hình trong các ứng dụng y sinh.

7.4 Hướng phát triển tương lai

- **Mở rộng bộ dữ liệu:** Để nâng cao tính tổng quát của mô hình, cần thu thập thêm AECG từ nhiều bà mẹ và các tư thế khác nhau, đảm bảo rằng mô hình có thể hoạt động hiệu quả trong các điều kiện thực tế đa dạng. Việc bổ sung dữ liệu từ các tình huống lâm sàng khác nhau sẽ giúp mô hình học được các đặc trưng phong phú hơn và giảm thiểu khả năng gặp phải sự cố khi xử lý tín hiệu trong các tình huống chưa gặp phải trong quá trình huấn luyện. Đồng thời, việc thu thập dữ liệu từ các nhóm dân cư có đặc điểm sinh lý khác nhau sẽ giúp mô hình trở nên linh hoạt và phù hợp hơn với các ứng dụng thực tế.
- **Adaptive wavelet:** Một hướng phát triển quan trọng là nghiên cứu và phát triển sóng mẹ tự động (adaptive wavelet). Thông thường, việc chọn sóng mẹ trong CWT có thể ảnh hưởng đáng kể đến khả năng phân tích tín hiệu, và việc chọn sóng mẹ cố định có thể không tối ưu cho tất cả các trường hợp tín hiệu. Do đó, nghiên cứu adaptive wavelet sẽ cho phép mô hình tự động điều chỉnh sóng mẹ theo đặc trưng tín hiệu của từng cá thể, giúp tối ưu hóa quá trình phân tích fECG. Việc điều chỉnh sóng mẹ linh hoạt sẽ giúp mô hình hoạt động hiệu quả hơn khi xử lý các tín hiệu có đặc điểm thay đổi theo thời gian hoặc giữa các cá thể.
- **Tích hợp real-time trên edge:** Để mở rộng khả năng ứng dụng của mô hình, một hướng phát triển tiếp theo là tối ưu hóa LiRA để triển khai real-time trên các thiết bị edge như FPGA hoặc MCU (Microcontroller Units), nhằm triển khai trên các thiết bị di động hoặc thiết bị y tế đeo tay. Việc tối ưu hóa mô hình trở nên gọn nhẹ hơn sẽ giúp giảm thiểu yêu cầu về tài nguyên tính toán, đồng thời đảm bảo mô hình có thể hoạt động trực tiếp trên các thiết bị di động với thời gian phản hồi nhanh chóng, phục vụ cho các ứng dụng giám sát sức khỏe thai nhi trong thời gian thực mà không cần phụ thuộc vào máy tính mạnh mẽ hoặc kết nối mạng.
- **Đánh giá lâm sàng:** Một bước quan trọng tiếp theo là thực hiện thử nghiệm lâm sàng với sự tham gia của các bác sĩ sản khoa, để so sánh kết quả đo fECG của mô hình LiRA với các phương pháp đo đặc truyền thống như siêu âm Doppler. Việc đánh giá mô hình trong môi trường lâm sàng sẽ giúp xác định độ chính xác, tính khả thi và mức độ phù hợp của LiRA khi được áp dụng vào thực tế, đồng thời giúp làm rõ các ưu điểm và hạn chế của mô hình trong việc giám sát sức khỏe thai nhi trong các tình huống thực tế.

- **Ứng dụng mở rộng:** Mô hình LiRA không chỉ giới hạn trong việc tách tín hiệu fECG mà còn có thể được áp dụng cho các tín hiệu y sinh khác. Một trong những hướng mở rộng là áp dụng phương pháp cho các tín hiệu PCG (Phonocardiogram) hoặc EEG (Electroencephalogram) để phân tích các tín hiệu sinh học khác, ví dụ như trong việc giám sát nhịp tim hoặc hoạt động não. Mô hình LiRA có thể được điều chỉnh để phù hợp với các tín hiệu này, mở ra khả năng ứng dụng rộng rãi trong các lĩnh vực chăm sóc sức khỏe và nghiên cứu y học.

KẾT LUẬN

Trong đồ án này, em đã phát triển và triển khai mô hình học sâu LiRA (LightResNet-AutoEncoder) để tách tín hiệu fECG từ AECG, với mục tiêu giảm nhiễu và tối ưu hóa khả năng phân tách tín hiệu. Các nhiệm vụ chính đã được giải quyết bao gồm xây dựng mô hình LiRA kết hợp giữa Autoencoder và Residual Networks (ResNet) để học và tái tạo tín hiệu fECG, sử dụng CWT để phân tích tín hiệu AECG trong miền thời gian và tần số, và đánh giá mô hình qua các chỉ số SNR, RMSE, MAPE, cùng khả năng phát hiện đỉnh R, với kết quả vượt trội so với các phương pháp truyền thống như ICA và EKF. Tuy nhiên, mô hình vẫn có một số hạn chế, bao gồm việc sử dụng bộ dữ liệu giới hạn, thiếu sự đa dạng về điều kiện lâm sàng và vị trí điện cực, cũng như gặp khó khăn khi tín hiệu fECG bị trộn lẫn mạnh với mECG hoặc nhiễu. Mặc dù vậy, mô hình đã hoàn thành mục tiêu chính là tách tín hiệu fECG từ AECG, mang lại kết quả đáng khích lệ trong việc giảm nhiễu và tái tạo tín hiệu chính xác, nhưng vẫn cần cải thiện trong việc xử lý tín hiệu phức tạp và mở rộng khả năng tổng quát của mô hình, đặc biệt khi thử nghiệm với các bộ dữ liệu đa dạng hơn và các kỹ thuật linh hoạt hơn.

TÀI LIỆU THAM KHẢO

- [1] P. S. Addison, “Wavelet transforms and the ecg: a review,” *Physiological Measurement*, vol. 26, no. 5, p. R155–R199, Aug. 2005.
- [2] K. J. Lee and B. Lee, “End-to-end deep learning architecture for separating maternal and fetal ecgs using w-net,” *IEEE Access*, vol. 10, p. 39782–39788, 2022.
- [3] H. Ghonchi and V. Abolghasemi, “A dual attention-based autoencoder model for fetal ecg extraction from abdominal signals,” *IEEE Sensors Journal*, vol. 22, no. 23, p. 22908–22918, Dec. 2022.
- [4] S. M. M. Martens, C. Rabotti, M. Mischi, and R. J. Sluijter, “A robust fetal ecg detection method for abdominal recordings,” *Physiological Measurement*, vol. 28, no. 4, p. 373–388, Mar. 2007.
- [5] R. Martinek, R. Kahankova, J. Jezewski, R. Jaros, J. Mohylova, M. Fajkus, J. Nedoma, P. Janku, and H. Nazeran, “Comparative effectiveness of ica and pca in extraction of fetal ecg from abdominal signals: Toward non-invasive fetal monitoring,” *Frontiers in Physiology*, vol. 9, May 2018.
- [6] R. Martinek, R. Kahankova, H. Nazeran, J. Konecny, J. Jezewski, P. Janku, P. Bilik, J. Zidek, J. Nedoma, and M. Fajkus, “Non-invasive fetal monitoring: A maternal surface ecg electrode placement-based novel approach for optimization of adaptive filter control parameters using the lms and rls algorithms,” *Sensors*, vol. 17, no. 5, p. 1154, May 2017.
- [7] J. Behar, A. Johnson, G. D. Clifford, and J. Oster, “A comparison of single channel fetal ecg extraction methods,” *Annals of Biomedical Engineering*, vol. 42, no. 6, p. 1340–1353, Mar. 2014.
- [8] M. R. Mohebbian, S. S. Vedaiei, K. A. Wahid, A. Dinh, H. R. Marateb, and K. Tavakolian, “Fetal ecg extraction from maternal ecg using attention-based cyclegan,” *IEEE Journal of Biomedical and Health Informatics*, vol. 26, no. 2, p. 515–526, Feb. 2022.
- [9] F.-W. La and P.-Y. Tsai, “Deep learning for detection of fetal ecg from multi-channel abdominal leads,” in *2018 Asia-Pacific Signal and Information Processing Association Annual Summit and Conference (APSIPA ASC)*. IEEE, Nov. 2018, p. 1397–1401.

- [10] S. Ziani, A. Jbari, and L. Belarbi, "Fetal electrocardiogram characterization by using only the continuous wavelet transform cwt," in *2017 International Conference on Electrical and Information Technologies (ICEIT)*. IEEE, Nov. 2017, p. 1–6.
- [11] Y. Alshebly and M. Nafea, "Isolation of fetal ecg signals from abdominal ecg using wavelet analysis," *IRBM*, vol. 41, no. 5, p. 252–260, Oct. 2020.
- [12] P. Darsana and V. N. Kumar, "Extracting fetal ecg signals through a hybrid technique utilizing two wavelet-based denoising algorithms," *IEEE Access*, vol. 11, p. 91696–91708, 2023.
- [13] V. D. Nguyen, "Fetal ecg extraction on time-frequency domain using conditional gan," in *2024 IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops (CVPRW)*. IEEE, Jun. 2024, p. 4943–4949.
- [14] S. Cerutti, G. Baselli, S. Civardi, E. Ferrazzi, A. M. Marconi, M. Pagani, and G. Pardi, "Variability analysis of fetal heart rate signals as obtained from abdominal electrocardiographic recordings," *Journal of Perinatal Medicine*, vol. 14, no. 6, p. 445–452, Jan. 1986.
- [15] S. Nikam and S. Deosarkar, "Fast ica based technique for non-invasive fetal ecg extraction," in *2016 Conference on Advances in Signal Processing (CASP)*. IEEE, Jun. 2016, p. 60–65.
- [16] L. Su and H.-T. Wu, "Extract fetal ecg from single-lead abdominal ecg by de-shape short time fourier transform and nonlocal median," *Frontiers in Applied Mathematics and Statistics*, vol. 3, Feb. 2017.
- [17] B. Rafaely and S. Elliot, "A computationally efficient frequency-domain lms algorithm with constraints on the adaptive filter," *IEEE Transactions on Signal Processing*, vol. 48, no. 6, p. 1649–1655, Jun. 2000.
- [18] G. P. S. KK, and J. SD, "Fetal heart rate extraction from abdominal electrocardiograms through multivariate empirical mode decomposition," *International Journal of Cardiovascular Research*, vol. 07, 2018.
- [19] Z. Wu, T. Lan, C. Yang, and Z. Nie, "A novel method to detect multiple arrhythmias based on time-frequency analysis and convolutional neural networks," *IEEE Access*, vol. 7, p. 170820–170830, 2019.
- [20] T. Wang, C. Lu, Y. Sun, M. Yang, C. Liu, and C. Ou, "Automatic ecg classification using continuous wavelet transform and convolutional neural network," *Entropy*, vol. 23, no. 1, p. 119, Jan. 2021.

- [21] J. e. a. Zhao, “Wavelet-based fetal ecg extraction: A deep learning approach,” *AISE Journal*, 2023.
- [22] I. Silva, J. Behar, R. Sameni, T. Zhu, J. Oster, G. D. Clifford, and G. B. Moody, “Noninvasive fetal ecg: The physionet/computing in cardiology challenge 2013,” in *Computing in Cardiology 2013*, 2013, pp. 149–152.
- [23] A. L. Goldberger, L. A. N. Amaral, L. Glass, J. M. Hausdorff, P. C. Ivanov, R. G. Mark, J. E. Mietus, G. B. Moody, C.-K. Peng, and H. E. Stanley, “Physiobank, physiotoolkit, and physionet: Components of a new research resource for complex physiologic signals,” *Circulation*, vol. 101, no. 23, Jun. 2000.
- [24] X. e. a. Zhou, “Deep learning-based fetal ecg extraction from abdominal signals,” *Nature Communications*, vol. 12, pp. 1–10, 2021.
- [25] J. e. a. Zhao, “A deep learning model for fetal ecg extraction using wavelet domain feature transformation,” *Applied Intelligence in Systems Engineering*, vol. 32, no. 1, 2023.
- [26] P. S. Addison, “Wavelets for electrocardiogram: Overview and taxonomy,” *Computers in Cardiology*, 2005.
- [27] S. Ahmad and Y. e. a. Zhang, “A review on fetal ecg signal processing using deep learning and hybrid techniques,” *Computer Methods and Programs in Biomedicine*, vol. 240, 2024.
- [28] W. Zhong, Z. Cao, X. Guo, and G. Wang, “A novel framework for maternal ecg removal from single-channel abdominal recording,” in *2019 IEEE International Conference on Bioinformatics and Biomedicine (BIBM)*. IEEE, Nov. 2019, p. 616–621.
- [29] W.-T. Zhang, Z.-Z. Huang, Y.-Y. Ma, and D.-J. Zhang, “A fast adaptive lpca method for fetal ecg extraction based on multichannel signals,” *IEEE Transactions on Instrumentation and Measurement*, vol. 73, pp. 1–11, 2024.

PHỤ LỤC



Hình 7.1 Giấy Chứng Nhận Sinh Viên Nghiên Cứu Khoa Học 2024 - 2025 .